
Inferencia de sonidos musicales usando
sintetizadores e IA
Title in English (defined in Cascaras\cover.tex)



Trabajo de Fin de Grado
Curso 2025–2026

Autor

David Cendejas Rodríguez
Ángel Jiménez Izquierdo

Director

Director 1

Director 2

Colaborador

Colaborador 1

Colaborador 2

Grado en Ingeniería Informática
Facultad de Informática
Universidad Complutense de Madrid

Inferencia de sonidos musicales usando
sintetizadores e IA
Title in English (defined in
Cascaras\cover.tex)

Trabajo de Fin de Grado en **Ingeniería Informática**

Autor

David Cendejas Rodríguez
Ángel Jiménez Izquierdo

Director

Director 1

Director 2

Colaborador

Colaborador 1

Colaborador 2

Convocatoria: *Febrero/Junio/Septiembre 2026*

Grado en Ingeniería Informática

Facultad de Informática

Universidad Complutense de Madrid

DIA de MES de AÑO

Dedicatoria

*A Pedro Pablo y Marco Antonio, por crear
TeXiS e iluminar nuestro camino*

Agradecimientos

A Guillermo, por el tiempo empleado en hacer estas plantillas. A Adrián, Enrique y Nacho, por sus comentarios para mejorar lo que hicimos. Y a Narciso, a quien no le ha hecho falta el Anillo Único para coordinarnos a todos.

Resumen

Inferencia de sonidos musicales usando sintetizadores e IA

Un resumen en castellano de media página, incluyendo el título en castellano. A continuación, se escribirá una lista de no más de 10 palabras clave.

Palabras clave

Máximo 10 palabras clave separadas por comas

Abstract

Title in English (defined in Cascaras\cover.tex)

An abstract in English, half a page long, including the title in English. Below, a list with no more than 10 keywords.

Keywords

10 keywords max., separated by commas.

Índice

1. Introducción	1
1.1. Motivación	2
1.2. Objetivos	2
1.3. Plan de trabajo	2
1.4. Explicaciones adicionales sobre el uso de esta plantilla	2
1.4.1. Texto de prueba	3
2. Estado de la Cuestión	7
3. Evolución Arquitectónica	9
3.1. Exploración de Paradigmas: Clasificación vs. Regresión	9
3.1.1. Enfoque de Clasificación	9
3.1.2. Enfoque de Regresión	10
3.2. El Problema de la Inyectividad y la Necesidad de una Arquitectura Compleja	11
3.2.1. Prototipo 4: Red Convolutiva de Doble Cabeza	11
3.2.2. Prototipo 4: Función de Pérdida Híbrida	12
4. Conclusiones y Trabajo Futuro	15
Introduction	17
Conclusions and Future Work	19
Contribuciones Personales	21
A. Título del Apéndice A	23
B. Título del Apéndice B	25

Índice de figuras

Índice de tablas

Introducción

“Frase célebre dicha por alguien inteligente”
— Autor

Según la normativa para Trabajos de Fin de Grado¹, la memoria incluirá una portada normalizada con la siguiente información: título en castellano, título en inglés, autores, profesor director, codirector si es el caso, curso académico e identificación de la asignatura (Trabajo de fin de grado del Grado en - nombre del grado correspondiente-, Facultad de Informática, Universidad Complutense de Madrid). Los datos referentes al título y director (y codirector en su caso) deben corresponder a los publicados en la página web de TFG.

La memoria debe incluir la descripción detallada de la propuesta hardware/software realizada y ha de contener:

- un índice,
- un resumen y una lista de no más de 10 palabras clave para su búsqueda bibliográfica, ambos en castellano e inglés,
- una introducción con los antecedentes, objetivos y plan de trabajo,
- resultados y discusión crítica y razonada de los mismos, con sus conclusiones,
- bibliografía.

Para facilitar la escritura de la memoria siguiendo esta estructura, el estudiante podrá usar las plantillas en LaTeX o Word preparadas al efecto y publicadas en la página web de TFG.

La memoria constará de un mínimo de 25 páginas para los proyectos realizados por un único estudiante, y de al menos 5 páginas más por cada integrante adicional del grupo. En este número de páginas solo se tiene en cuenta el contenido correspondiente a los apartados c y d del punto anterior.

La memoria puede estar escrita en castellano o inglés, pero en el primer caso la introducción y las conclusiones deben aparecer también en inglés. Las memorias de

¹<https://informatica.ucm.es/file/normativatfg-2021-2022?ver> (ver versión actualizada para cada curso académico)

los TFG matriculados en el grupo I deberán estar escritas íntegramente en inglés, excepto por lo especificado en los puntos 1 y 2 anteriores (título, resumen y lista de palabras clave).

En caso de trabajos no unipersonales, cada participante indicará en la memoria su contribución al proyecto con una extensión de al menos dos páginas por cada uno de los participantes.

Todo el material no original, ya sea texto o figuras, deberá ser convenientemente citado y referenciado. En el caso de material complementario se deben respetar las licencias y *copyrights* asociados al software y hardware que se emplee. En caso contrario no se autorizará la defensa, sin menoscabo de otras acciones que correspondan.

1.1. Motivación

Introducción al tema del TFG.

1.2. Objetivos

Descripción de los objetivos del trabajo.

1.3. Plan de trabajo

Aquí se describe el plan de trabajo a seguir para la consecución de los objetivos descritos en el apartado anterior.

1.4. Explicaciones adicionales sobre el uso de esta plantilla

Si quieres cambiar el **estilo del título** de los capítulos del documento, edita el fichero `TeXiS\TeXiS_pream.tex` y comenta la línea `\usepackage[Lenny]{fncychap}` para dejar el estilo básico de $\text{\LaTeX}$.

Si no te gusta que no haya **espacios entre párrafos** y quieres dejar un pequeño espacio en blanco, no metas saltos de línea (`\\`) al final de los párrafos. En su lugar, busca el comando `\setlength{\parskip}{0.2ex}` en `TeXiS\TeXiS_pream.tex` y aumenta el valor de `0,2ex` a, por ejemplo, `1ex`.

TFGTeXiS se ha elaborado a partir de la plantilla de TeXiS², creada por Marco Antonio y Pedro Pablo Gómez Martín para escribir su tesis doctoral. Para explicaciones más extensas y detalladas sobre cómo usar esta plantilla, recomendamos la lectura del documento `TeXiS-Manual-1.0.pdf` que acompaña a esta plantilla.

El siguiente texto se genera con el comando `\lipsum[2-20]` que viene a continuación en el fichero `.tex`. El único propósito es mostrar el aspecto de las páginas

²<http://gaia.fdi.ucm.es/research/texis/>

usando esta plantilla. Quita este comando y, si quieres, comenta o elimina el paquete *lipsum* al final de `TeXiS\TeXiS_pream.tex`

1.4.1. Texto de prueba

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta

tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.

Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, nonummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

Etiam euismod. Fusce facilisis lacinia dui. Suspendisse potenti. In mi erat, cursus id, nonummy sed, ullamcorper eget, sapien. Praesent pretium, magna in eleifend egestas, pede pede pretium lorem, quis consectetur tortor sapien facilisis magna. Mauris quis magna varius nulla scelerisque imperdiet. Aliquam non quam. Aliquam porttitor quam a lacus. Praesent vel arcu ut tortor cursus volutpat. In vitae pede quis diam bibendum placerat. Fusce elementum convallis neque. Sed dolor orci, scelerisque ac, dapibus nec, ultricies ut, mi. Duis nec dui quis leo sagittis commodo.

Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis

congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

Nulla mattis luctus nulla. Duis commodo velit at leo. Aliquam vulputate magna et leo. Nam vestibulum ullamcorper leo. Vestibulum condimentum rutrum mauris. Donec id mauris. Morbi molestie justo et pede. Vivamus eget turpis sed nisl cursus tempor. Curabitur mollis sapien condimentum nunc. In wisi nisl, malesuada at, dignissim sit amet, lobortis in, odio. Aenean consequat arcu a ante. Pellentesque porta elit sit amet orci. Etiam at turpis nec elit ultricies imperdiet. Nulla facilisi. In hac habitasse platea dictumst. Suspendisse viverra aliquam risus. Nullam pede justo, molestie nonummy, scelerisque eu, facilisis vel, arcu.

Curabitur tellus magna, porttitor a, commodo a, commodo in, tortor. Donec interdum. Praesent scelerisque. Maecenas posuere sodales odio. Vivamus metus lacus, varius quis, imperdiet quis, rhoncus a, turpis. Etiam ligula arcu, elementum a, venenatis quis, sollicitudin sed, metus. Donec nunc pede, tincidunt in, venenatis vitae, faucibus vel, nibh. Pellentesque wisi. Nullam malesuada. Morbi ut tellus ut pede tincidunt porta. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam congue neque id dolor.

Donec et nisl at wisi luctus bibendum. Nam interdum tellus ac libero. Sed sem justo, laoreet vitae, fringilla at, adipiscing ut, nibh. Maecenas non sem quis tortor eleifend fermentum. Etiam id tortor ac mauris porta vulputate. Integer porta neque vitae massa. Maecenas tempus libero a libero posuere dictum. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Aenean quis mauris sed elit commodo placerat. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Vivamus rhoncus tincidunt libero. Etiam elementum pretium justo. Vivamus est. Morbi a tellus eget pede tristique commodo. Nulla nisl. Vestibulum sed nisl eu sapien cursus rutrum.

Nulla non mauris vitae wisi posuere convallis. Sed eu nulla nec eros scelerisque

pharetra. Nullam varius. Etiam dignissim elementum metus. Vestibulum faucibus, metus sit amet mattis rhoncus, sapien dui laoreet odio, nec ultricies nibh augue a enim. Fusce in ligula. Quisque at magna et nulla commodo consequat. Proin accum-san imperdiet sem. Nunc porta. Donec feugiat mi at justo. Phasellus facilisis ipsum quis ante. In ac elit eget ipsum pharetra faucibus. Maecenas viverra nulla in massa.

Nulla ac nisl. Nullam urna nulla, ullamcorper in, interdum sit amet, gravida ut, risus. Aenean ac enim. In luctus. Phasellus eu quam vitae turpis viverra pellentesque. Duis feugiat felis ut enim. Phasellus pharetra, sem id porttitor sodales, magna nunc aliquet nibh, nec blandit nisl mauris at pede. Suspendisse risus risus, lobortis eget, semper at, imperdiet sit amet, quam. Quisque scelerisque dapibus nibh. Nam enim. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Nunc ut metus. Ut metus justo, auctor at, ultrices eu, sagittis ut, purus. Aliquam aliquam.

Capítulo 2

Estado de la Cuestión

En el estado de la cuestión es donde aparecen gran parte de las referencias bibliográficas del trabajo. Una de las formas más cómodas de gestionar la bibliografía en $\text{\LaTeX}$ es utilizando **bibtex**. Las entradas bibliográficas deben estar en un fichero con extensión *.bib* (con esta plantilla se proporciona el fichero *biblio.bib*, donde están las entradas referenciadas más abajo). Cada entrada bibliográfica tiene una clave que permite referenciarla desde cualquier parte del texto con los siguiente comandos:

- Referencia bibliografica con cite: ?
- Referencia bibliográfica con citep: (?)
- Referencia bibliográfica con citet: ?

Es posible citar más de una fuente, como por ejemplo (???)

Después, $\text{\LaTeX}$ se ocupa de rellenar la sección de bibliografía con las entradas **que hayan sido citadas** (es decir, no con todas las entradas que hay en el *.bib*, sino sólo con aquellas que se hayan citado en alguna parte del texto).

Bibtex es un programa separado de latex, pdf_{flat}tex o cualquier otra cosa que se use para compilar los *.tex*, de manera que para que se rellene correctamente la sección de bibliografía es necesario compilar primero el trabajo (a veces es necesario compilarlo dos veces), compilar después con bibtex, y volver a compilar otra vez el trabajo (de nuevo, puede ser necesario compilarlo dos veces).

Evolución Arquitectónica

3.1. Exploración de Paradigmas: Clasificación vs. Regresión

3.1.1. Enfoque de Clasificación

La clasificación es el paso previo natural a la búsqueda de un modelo de inferencia de parámetros. De esta manera, se puede comprobar de forma práctica que la red neuronal procesa el audio adecuadamente y es capaz de conservar su información acústica fundamental.

El **Prototipo 1** es una prueba de concepto para la primera aproximación al aprendizaje automático aplicado al audio. En él se utiliza un dataset reducido, construido con la librería NumPy, de alrededor de 50 archivos *.wav* de un segundo de duración. Estos audios se generan sintéticamente con frecuencias aleatorias y formas de onda básicas (*sine*, *square*, *sawtooth*, *triangle* y *noise*).

En la fase de preprocesamiento y entrenamiento, desarrollada utilizando TensorFlow, se opta por no aportar a la red formas de audio crudo. En su lugar, se extraen las características calculando los Coeficientes Cepstrales en las Frecuencias de Mel (MFCC) de cada muestra. El modelo tiene el objetivo de clasificar y asociar la matriz de coeficientes con la etiqueta correspondiente a su tipo de onda. A pesar de esto, al plantear una arquitectura básica no convolucional, la red neuronal carece de los mecanismos para realizar una interpretación correcta de los patrones bidimensionales de los MFCC. Como consecuencia, el modelo arroja una precisión muy baja.

El **Prototipo 2** se basa en el **Prototipo 1**. Sigue atendiendo al objetivo de la clasificación, pero tiene características que difieren del anterior. Esta vez, los audios se convierten a espectrogramas *.png* mediante el uso de la librería de *librosa*. Esto conlleva un menor coste computacional y de almacenamiento. Al tratarse realmente de imágenes, se pueden utilizar modelos preentrenados de visión, encargados de clasificar imágenes.

Para el entrenamiento, se hace uso de **ResNet34 preentrenada** vía *fastAI*. Para su adaptación, se utilizan **DataBlocks**, una herramienta de *fastAI* mediante la cual

se especifican que las entradas son las imágenes (espectrogramas) y las salidas son las categorías (tipo de onda). Asimismo, se etiqueta obteniendo la categoría a partir del nombre archivo y se divide destinando un 80 % de las imágenes para entrenar y un 20 % para validación.

Como resultado de utilizar una red convolucional y la arquitectura externa **ResNet34**, el modelo obtuvo una buena precisión, especialmente identificando ondas puras dentro del rango entrenado.

3.1.2. Enfoque de Regresión

Al plantear un salto hacia la síntesis paramétrica continua, fue necesario tomar una decisión de diseño fundamental: la elección del motor de síntesis. Tras la evaluación de distintas alternativas, se optó por centrar el proyecto en la síntesis por Modulación de Frecuencia (FM). Esta técnica presenta ventajas claras para el aprendizaje automático. A diferencia de la síntesis aditiva, que requiere decenas de osciladores simultáneos, la síntesis FM es muy eficiente, consiguiendo generar timbres complejos a partir de un número reducido de parámetros. De esta forma, se puede comenzar utilizando, por ejemplo, la frecuencia portadora, el ratio y el índice de modulación, y luego ampliar el número de variables para conseguir sonidos más complejos. Estas características acotan la dimensionalidad del problema predictivo, haciéndolo viable para la red neuronal.

Si bien con la clasificación queda validada la extracción de características acústicas, una vez tomada esta última decisión, deja de ser útil. Para la inferencia de parámetros de la síntesis FM, resulta obligatoria la evolución hacia una arquitectura de regresión.

Para el **Prototipo 3** se genera un dataset mediano de aproximadamente 15000 muestras, construido mediante un barrido de parámetros en un sintetizador FM de **pyo**. Para la reducción de la carga computacional y la optimización del espacio, se sustituye **librosa** por la librería de *torchaudio*. Esta permite transformar los archivos de audio (*.wav*) en tensores de espectrogramas (*.pt*), asociados mediante el uso de un (*.csv*) a sus valores numéricos. El 80 % del conjunto de datos se destina a entrenamiento y el otro 20 % a validación.

El entrenamiento se implementa mediante **PyTorch**. Se diseña una arquitectura convolucional propia (SmallCNNRegressor). La red neuronal se compone de dos bloques principales: uno de extracción de características y una cabeza de regresión.

El primer bloque recibe los espectrogramas en forma de tensores de un único canal (lo que equivaldría a imágenes en escala de grises) y los procesa en otros tres bloques convolucionales. Cada uno de estos aplica kernels de tamaño 3x3 (o núcleos convolucionales) que se deslizan sobre la matriz del espectrograma para extraer características espaciales, detectando así patrones visuales en la representación espectral del sonido. A esto le sigue una función de activación no lineal **ReLU** y una capa de reducción espacial (**Max Pooling**). El último bloque convolucional termina en una capa de agrupamiento (**Adaptive Average Pooling**), que comprime los mapas de características a una matriz 4x4.

El siguiente paso es la cabeza de regresión, en donde la información espacio-temporal del espectrograma (extraída en el bloque anterior), se pasa a un vector de

una única dimensión y atraviesa dos capas completamente conectadas (**Perceptrón Multicapa**). La primera, comprime la información a 128 neuronas, y la segunda, saca el vector por una dimensión de salida de tamaño 3, que se corresponde con los tres parámetros del sintetizador: frecuencia portadora, ratio y el índice de modulación.

El modelo optimiza el proceso de los espectrogramas mediante el algoritmo Adam, utilizando el Error Cuadrático Medio (MSELoss) como función de pérdida. Y, en cuanto al ciclo de entrenamiento, este se configuró con una duración de 5 épocas (*epochs*). En este prototipo se decidió no hacer una búsqueda extensa de hiperparámetros al tratarse de un prototipo intermedio, con un fin de experimentación inicial con la regresión.

A pesar de esto, se puede observar una precisión muy limitada en los resultados experimentales. Se consigue mantener un MSE bajo en el *Ratio* e *Index*, pero el error en el *Carrier* resulta desproporcionado, debido a operar en la escala de miles de hercios. De este prototipo se puede sacar la conclusión de que el minimizar el error matemático sobre los parámetros no garantiza la similitud acústica del sonido generado.

3.2. El Problema de la Inyectividad y la Necesidad de una Arquitectura Compleja

El **Prototipo 3** contiene una limitación fundamental muy relevante en la síntesis FM: su inyectividad es nula. Esto quiere decir que diferentes combinaciones de parámetros pueden dar lugar a sonidos idénticos. Un ejemplo, radical pero que explica muy bien este resultado, es un caso en el que el índice de modulación sea 0. En ese caso, no es verdaderamente relevante el valor del ratio, sin embargo, la función de pérdida, implementada con **MSE**, penaliza gravemente que este difiera del original. Este obstáculo hace que se tenga que replantear la función de pérdida.

3.2.1. Prototipo 4: Red Convolucional de Doble Cabeza

El **Prototipo 4** se diseña para solucionar el problema de la inyectividad, tratando de asegurar que la inferencia de parámetros se corresponda con la fidelidad acústica. Este modelo se basa en una arquitectura convolucional de doble cabeza (**Encoder-Decoder**).

En cuanto al preprocesamiento del conjunto de datos, se implementa una mejora para evitar que la diferencia tan grande entre las escalas de difentes parámetros (como la frecuencia portadora frente al ratio) comprometa el cálculo del gradiente. Los tensores se normalizan estadísticamente (**Z-score**), restando la media y dividiendo por la desviación estándar de cada parámetro.

Para cada parámetro x , el valor normalizado z se calcula según la Ecuación 3.1:

$$z = \frac{x - \mu}{\sigma} \quad (3.1)$$

Donde μ representa la media aritmética de dicho parámetro en todo el dataset de entrenamiento y σ su desviación estándar.

La topología de la red (CNNRegressor4), consta de un procesamiento dividido en varias fases:

Primero se pasa por un Codificador (**Encoder**), el cual consta de una secuencia de tres bloques convolucionales que convierten el espectrograma inicial en una representación comprimida, extrayendo así sus características fundamentales. Para ello, cada bloque aplica núcleos (kernels) de 3x3. Posteriormente, pasa por una capa de normalización por lotes (Batch Normalization), que estabiliza y acelera el entrenamiento, y una activación no lineal ReLU. Finalmente, se aplica una reducción espacial en cada bloque (Max Pooling). Con todo esto, la matriz se ha reducido a una octava parte de su tamaño original y la profundidad de la red ha incrementado de 1 a 128 canales. Como resultado, se obtiene una representación comprimida rica en características acústicas.

Al salir del **Encoder**, el flujo de datos atraviesa lo que se denomina como cuello de botella (**Bottleneck**). Este bloque convolucional no aplica una reducción espacial, manteniendo estables las dimensiones de la matriz. Su función es duplicar el número de canales (profundidad del tensor), pasando de 128 a 256 canales. Esto se hace con la finalidad de mezclar los patrones que el **Encoder** ha extraído previamente, creando una representación densa y unificada.

Después se pasa por la fase de Inferencia Numérica, donde ocurre la regresión de los parámetros del sintetizador FM (frecuencia portadora, ratio e índice). Se aplica una capa de agrupamiento global (Adaptive Average Pooling) ya que los parámetros describen el sonido completo y no un punto temporal concreto en el espectrograma. Para ello, se calcula la media de todas las posiciones de cada canal, quedándose con un único número como resumen por canal. Finalmente, el vector unidimensional, resultado del proceso anterior, atraviesa un **Perceptrón Multicapa**, que lo proyecta hacia las tres neuronas de salida.

Por último, se encuentra la fase de Reconstrucción (**Decoder**), la cual se encarga de reconstruir el espectrograma original a partir de la representación comprimida del **Bottleneck**. Como el **Encoder** comprime tres veces, el **Decoder** descomprime tres veces. Para ello, utiliza tres capas convolucionales transpuestas (ConvTranspose2d).

El motivo para utilizar el **Decoder** es como método de regularización forzada del **Encoder**. En el caso en el que el codificador borre información importante, como armónicos o patrones temporales, que no afecte directamente a los parámetros de la regresión, el (**Decoder**) no será capaz de redibujar correctamente el espectrograma, disparando así el error en la función de pérdida híbrida. Aparte, si el **Bottleneck** no guarda suficiente información, ocurrirá lo mismo. Todo esto fuerza, mediante el cálculo de gradientes, a que las capas iniciales aprendan a conservar el timbre y la representación del sonido.

3.2.2. Prototipo 4: Función de Pérdida Híbrida

Con el objetivo de solucionar el problema de la inyectividad, se consolida el uso de utilizando Función de Pérdida Híbrida, abandonando el Error Cuadrático Medio (MSE). Esta función evalúa la pérdida de dos formas simultáneamente, dándole prioridad a la similitud y convergencia de espectrogramas (pérdida y convergencia espectral) y dejando en segundo plano la similitud de los parámetros (pérdida

paramétrica).

Por un lado tenemos la **Pérdida y Convergencia Espectral**. Estas funciones son las principales para la composición del error, teniendo mucho más peso que la pérdida paramétrica, y estando encargadas de asegurar que un sonido generado sea acústicamente similar al original.

La **pérdida espectral** se calcula mediante el Error Cuadrático Medio (**L1 Loss**), el cual mide la diferencia directa entre espectrogramas (píxel a píxel) en escala logarítmica (dB), siendo la métrica de mayor peso para el error. Con esto se garantiza unos picos de energía y formas generales que coincidan en tiempo y frecuencia.

Matemáticamente, si S es el espectrograma original en decibelios y $\hat{S}$ el reconstruido, ambos con N elementos, la pérdida L1 se define como:

$$L_1 = \frac{1}{N} \sum_{i=1}^N |S_i - \hat{S}_i| \quad (3.2)$$

En cuanto a la **convergencia espectral**, es un refuerzo (tiene un peso bajo) para la pérdida espectral, que compara las magnitudes de forma relativa con la norma de Frobenius, capturando la estructura global del espectro (como los armónicos y la energía). Estas características son muy relevantes para encontrar una representación fiel al timbre original.

La convergencia espectral (C_S) emplea la norma de Frobenius ($\|\cdot\|_F$) sobre las magnitudes matriciales para medir la distancia relativa entre las energías, tal y como detalla la Ecuación 3.3:

$$C_S = \frac{\|S - \hat{S}\|_F}{\|S\|_F} \quad (3.3)$$

Por último se encuentra la **Pérdida Paramétrica**, aplicada mediante **SmoothL1**. Esta penaliza las diferencias en los parámetros del sintetizador, por lo que no se elimina totalmente la regresión numérica de los parámetros, pero se le da un peso considerablemente bajo.

La Ecuación 3.4 muestra el comportamiento por tramos de SmoothL1 para una predicción $\hat{y}$ frente a su valor real y :

$$L_{smooth} = \begin{cases} 0.5(y - \hat{y})^2, & \text{si } |y - \hat{y}| < 1 \\ |y - \hat{y}| - 0.5, & \text{en caso contrario} \end{cases} \quad (3.4)$$

La ponderación de los pesos en la función de pérdida híbrida es fundamental para el correcto aprendizaje del Modelo y también para solucionar el problema de la inyectividad. Se le otorga un peso completo (1.0) a la pérdida espectral, un peso medio (0.5) a la convergencia espectral y un peso muy bajo (0.05) a la pérdida paramétrica. De esta manera, en el caso de que la red infiera una serie de parámetros que difieran considerablemente de los parámetros originales, si sus espectrogramas son muy similares (y, por tanto, su timbre también lo es), el error será mínimo. El modelo debe memorizar números exactos, si no que analiza la imagen del sonido, su espectrograma.

Capítulo 4

Conclusiones y Trabajo Futuro

Conclusiones del trabajo y líneas de trabajo futuro.

Antes de la entrega de actas de cada convocatoria, en el plazo que se indica en el calendario de los trabajos de fin de grado, el estudiante entregará en el Campus Virtual la versión final de la memoria en PDF.

Introduction

Introduction to the subject area. This chapter contains the translation of Chapter 1.

Conclusions and Future Work

Conclusions and future lines of work. This chapter contains the translation of Chapter 4.

Contribuciones Personales

En caso de trabajos no unipersonales, cada participante indicará en la memoria su contribución al proyecto con una extensión de al menos dos páginas por cada uno de los participantes.

En caso de trabajo unipersonal, elimina esta página en el fichero `TFGTeXiS.tex` (comenta o borra la línea `\include{Capitulos/ContribucionesPersonales}`).

Estudiante 1

Al menos dos páginas con las contribuciones del estudiante 1.

Estudiante 2

Al menos dos páginas con las contribuciones del estudiante 2. En caso de que haya más estudiantes, copia y pega una de estas secciones.

Apéndice **A**

Título del Apéndice A

Los apéndices son secciones al final del documento en las que se agrega texto con el objetivo de ampliar los contenidos del documento principal.

Apéndice	B
----------	----------

Título del Apéndice B

Se pueden añadir los apéndices que se consideren oportunos.

Este texto se puede encontrar en el fichero Cascaras/fin.tex. Si deseas eliminarlo, basta con comentar la línea correspondiente al final del fichero TFGTeXiS.tex.

*–¿Qué te parece desto, Sancho? – Dijo Don Quijote –
Bien podrán los encantadores quitarme la ventura,
pero el esfuerzo y el ánimo, será imposible.*

*Segunda parte del Ingenioso Caballero
Don Quijote de la Mancha
Miguel de Cervantes*

*–Buena está – dijo Sancho –; fírmela vuestra merced.
–No es menester firmarla – dijo Don Quijote–,
sino solamente poner mi rúbrica.*

*Primera parte del Ingenioso Caballero
Don Quijote de la Mancha
Miguel de Cervantes*

