
Inferencia de sonidos musicales usando
sintetizadores e IA
Inference of musical sounds using synthesizers
and AI



Trabajo de Fin de Grado
Curso 2025–2026

Autor

David Cendejas Rodríguez
Ángel Jiménez Izquierdo

Director

Miguel Gómez-Zamalloa Gil
Jaime Sánchez Hernández

Grado en Ingeniería de Computadores
Grado en Ingeniería Informática
Facultad de Informática
Universidad Complutense de Madrid

Inferencia de sonidos musicales usando
sintetizadores e IA
Inference of musical sounds using
synthesizers and AI

Trabajo de Fin de Grado en Ingeniería de Computadores /
Ingeniería Informática

Autor

David Cendejas Rodríguez
Ángel Jiménez Izquierdo

Director

Miguel Gómez-Zamalloa Gil
Jaime Sánchez Hernández

Convocatoria: *Junio 2026*

Grado en Ingeniería de Computadores
Grado en Ingeniería Informática
Facultad de Informática
Universidad Complutense de Madrid

25 de Mayo de 2026

Dedicatoria

*A Miguel y a Jaime, por su paciencia y por
habernos introducido en el mundo de la
informática musical y la investigación
académica.*

*A Carlos, por su guía en las tareas de machine
learning.*

*A nuestras familias y amigos, por su cariño y
apoyo incondicional.*

Agradecimientos

A cualquier persona involucrada en el despegue de nuestras carreras profesionales como informáticos a lo largo de estos cuatro años: profesores, compañeros, familia y amigos.

Resumen

Inferencia de sonidos musicales usando sintetizadores e IA

Un resumen en castellano de media página, incluyendo el título en castellano. A continuación, se escribirá una lista de no más de 10 palabras clave.

Palabras clave

Máximo 10 palabras clave separadas por comas

Abstract

Inference of musical sounds using synthesizers and AI

An abstract in English, half a page long, including the title in English. Below, a list with no more than 10 keywords.

Keywords

10 keywords max., separated by commas.

Índice

1. Introducción	1
1.1. Motivación	2
1.2. Objetivos	2
1.3. Plan de trabajo	2
1.4. Explicaciones adicionales sobre el uso de esta plantilla	2
1.4.1. Texto de prueba	3
2. Estado de la Cuestión	7
2.1. Estado de la cuestión: Audio	7
2.1.1. Síntesis sonora	7
2.1.2. Síntesis por Modulación de Frecuencia (FM) y el Yamaha DX7	8
2.1.3. Representación digital del sonido: La onda como vector	8
2.1.4. Representación espectral: STFT y Espectrogramas	9
2.1.5. Escala de Mel	10
2.1.6. <i>Mel Frequency Cepstral Coefficients</i> (MFCC)	10
2.2. Estado de la cuestión: IA aplicada al audio	10
2.2.1. CNNs en el dominio del audio	10
2.2.2. Audio Spectrogram Transformer (AST)	11
2.2.3. Inferencia de parámetros en síntesis	11
2.2.4. Audio End-to-End vs. Parámetros + Espectrograma	12
2.2.5. Datasets de referencia: NSynth y otros	12
2.3. Evaluación (mover?)	12
2.3.1. Fréchet Audio Distance (FAD)	12
3. Evolución Arquitectónica	15
3.1. Exploración de Paradigmas: Clasificación vs. Regresión	15
3.1.1. Enfoque de Clasificación	15
3.1.2. Enfoque de Regresión	16
3.2. El Problema de la Inyectividad y la Necesidad de una Arquitectura Compleja	17
3.2.1. Prototipo 4: Red Convolutiva de Doble Cabeza	18
3.2.2. Prototipo 4: Función de Pérdida Híbrida	19

4. Experimentación Previa	21
4.1. Limitaciones de Fréchet Audio Distance (FAD)	21
4.2. Validación por Fuerza Bruta (Grid Search)	21
4.2.1. Diseño experimental y parametrización del Grid Search	22
4.2.2. Espectrograma de Mel	23
4.2.3. Espectrograma MFCC	24
4.2.4. Conclusiones	25
5. Arquitectura Final	27
5.1. Expansión Paramétrica: Evolventes y Generación Aleatoria del Dataset	27
5.1.1. Generación y Tratamiento del Dataset	27
5.1.2. Entrenamiento	29
5.1.3. Inferencia	31
5.1.4. Evaluación	31
5.2. Interfaz Gráfica de la Aplicación	32
5.3. Estructura del Código	33
6. Resultados y Evaluación	37
6.1. Definición de los Pipelines Experimentales	37
6.2. Evaluación de las Diferentes Arquitecturas y Funciones de Pérdida . .	37
6.2.1. P1: CNNRegressorSimple: SmoothL1, STFT lineal	39
6.2.2. P2: CNNRegressorSimple: SmoothL1, Mel (log-perceptual) . .	39
6.2.3. P3: CNNRegressor5: HybridLoss, STFT lineal	39
6.2.4. P4: CNNRegressor5: HybridLoss, Mel (log-perceptual)	39
6.2.5. P5: CNNRegressor5: MultiScaleSpectralLoss, STFT lineal . .	39
6.2.6. P6: CNNRegressor5: MultiScaleSpectralLoss, Mel (log-perceptual)	39
6.3. Comparación de los Resultados Obtenidos	39
7. Conclusiones y Trabajo Futuro	41
Introduction	43
Conclusions and Future Work	45
Contribuciones Personales	47
Bibliografía	49
A. Título del Apéndice A	51
B. Título del Apéndice B	53
Bibliografía	57

Índice de figuras

2.1. Representación del muestreo de una onda continua a intervalos regulares. Fuente: Adaptado de Refraction Productions (2023).	9
2.2. Ejemplo de un espectrograma. Fuente: Adaptado de ?.	9
5.1. Flujo de trabajo del Prototipo 5: desde la síntesis matemática hasta la inferencia y evaluación del modelo.	28
5.2. Primera pantalla de la Interfaz Gráfica de la Aplicación, elección uso modelo o entrenamiento.	34
5.3. Pantalla en la que se pueden hacer pruebas con el modelo seleccionado.	34
5.4. Sintetizador FM de prueba.	35
5.5. Sintetizador FM de prueba.	35
6.1. Representación de las diferentes combinaciones de Arquitecturas y Funciones de Pérdida.	38

Índice de tablas

6.1. Comparativa de métricas paramétricas y acústicas sobre el Test Set para los 6 pipelines. Las flechas ($\downarrow$) indican que un valor menor representa un mejor rendimiento. El Decoder L1 no aplica (N/A) en las arquitecturas simples.	39
--	----

Introducción

“Frase célebre dicha por alguien inteligente”
— Autor

Según la normativa para Trabajos de Fin de Grado¹, la memoria incluirá una portada normalizada con la siguiente información: título en castellano, título en inglés, autores, profesor director, codirector si es el caso, curso académico e identificación de la asignatura (Trabajo de fin de grado del Grado en - nombre del grado correspondiente-, Facultad de Informática, Universidad Complutense de Madrid). Los datos referentes al título y director (y codirector en su caso) deben corresponder a los publicados en la página web de TFG.

La memoria debe incluir la descripción detallada de la propuesta hardware/software realizada y ha de contener:

- un índice,
- un resumen y una lista de no más de 10 palabras clave para su búsqueda bibliográfica, ambos en castellano e inglés,
- una introducción con los antecedentes, objetivos y plan de trabajo,
- resultados y discusión crítica y razonada de los mismos, con sus conclusiones,
- bibliografía.

Para facilitar la escritura de la memoria siguiendo esta estructura, el estudiante podrá usar las plantillas en LaTeX o Word preparadas al efecto y publicadas en la página web de TFG.

La memoria constará de un mínimo de 25 páginas para los proyectos realizados por un único estudiante, y de al menos 5 páginas más por cada integrante adicional del grupo. En este número de páginas solo se tiene en cuenta el contenido correspondiente a los apartados c y d del punto anterior.

La memoria puede estar escrita en castellano o inglés, pero en el primer caso la introducción y las conclusiones deben aparecer también en inglés. Las memorias de

¹<https://informatica.ucm.es/file/normativatfg-2021-2022?ver> (ver versión actualizada para cada curso académico)

los TFG matriculados en el grupo I deberán estar escritas íntegramente en inglés, excepto por lo especificado en los puntos 1 y 2 anteriores (título, resumen y lista de palabras clave).

En caso de trabajos no unipersonales, cada participante indicará en la memoria su contribución al proyecto con una extensión de al menos dos páginas por cada uno de los participantes.

Todo el material no original, ya sea texto o figuras, deberá ser convenientemente citado y referenciado. En el caso de material complementario se deben respetar las licencias y *copyrights* asociados al software y hardware que se emplee. En caso contrario no se autorizará la defensa, sin menoscabo de otras acciones que correspondan.

1.1. Motivación

Introducción al tema del TFG.

1.2. Objetivos

Descripción de los objetivos del trabajo.

1.3. Plan de trabajo

Aquí se describe el plan de trabajo a seguir para la consecución de los objetivos descritos en el apartado anterior.

1.4. Explicaciones adicionales sobre el uso de esta plantilla

Si quieres cambiar el **estilo del título** de los capítulos del documento, edita el fichero `TeXiS\TeXiS_pream.tex` y comenta la línea `\usepackage[Lenny]{fncychap}` para dejar el estilo básico de $\text{\LaTeX}$.

Si no te gusta que no haya **espacios entre párrafos** y quieres dejar un pequeño espacio en blanco, no metas saltos de línea (`\\`) al final de los párrafos. En su lugar, busca el comando `\setlength{\parskip}{0.2ex}` en `TeXiS\TeXiS_pream.tex` y aumenta el valor de `0,2ex` a, por ejemplo, `1ex`.

TFGTeXiS se ha elaborado a partir de la plantilla de TeXiS², creada por Marco Antonio y Pedro Pablo Gómez Martín para escribir su tesis doctoral. Para explicaciones más extensas y detalladas sobre cómo usar esta plantilla, recomendamos la lectura del documento `TeXiS-Manual-1.0.pdf` que acompaña a esta plantilla.

El siguiente texto se genera con el comando `\lipsum[2-20]` que viene a continuación en el fichero `.tex`. El único propósito es mostrar el aspecto de las páginas

²<http://gaia.fdi.ucm.es/research/texis/>

usando esta plantilla. Quita este comando y, si quieres, comenta o elimina el paquete *lipsum* al final de `TeXiS\TeXiS_pream.tex`

1.4.1. Texto de prueba

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta

tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.

Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, nonummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

Etiam euismod. Fusce facilisis lacinia dui. Suspendisse potenti. In mi erat, cursus id, nonummy sed, ullamcorper eget, sapien. Praesent pretium, magna in eleifend egestas, pede pede pretium lorem, quis consectetur tortor sapien facilisis magna. Mauris quis magna varius nulla scelerisque imperdiet. Aliquam non quam. Aliquam porttitor quam a lacus. Praesent vel arcu ut tortor cursus volutpat. In vitae pede quis diam bibendum placerat. Fusce elementum convallis neque. Sed dolor orci, scelerisque ac, dapibus nec, ultricies ut, mi. Duis nec dui quis leo sagittis commodo.

Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis

congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

Nulla mattis luctus nulla. Duis commodo velit at leo. Aliquam vulputate magna et leo. Nam vestibulum ullamcorper leo. Vestibulum condimentum rutrum mauris. Donec id mauris. Morbi molestie justo et pede. Vivamus eget turpis sed nisl cursus tempor. Curabitur mollis sapien condimentum nunc. In wisi nisl, malesuada at, dignissim sit amet, lobortis in, odio. Aenean consequat arcu a ante. Pellentesque porta elit sit amet orci. Etiam at turpis nec elit ultricies imperdiet. Nulla facilisi. In hac habitasse platea dictumst. Suspendisse viverra aliquam risus. Nullam pede justo, molestie nonummy, scelerisque eu, facilisis vel, arcu.

Curabitur tellus magna, porttitor a, commodo a, commodo in, tortor. Donec interdum. Praesent scelerisque. Maecenas posuere sodales odio. Vivamus metus lacus, varius quis, imperdiet quis, rhoncus a, turpis. Etiam ligula arcu, elementum a, venenatis quis, sollicitudin sed, metus. Donec nunc pede, tincidunt in, venenatis vitae, faucibus vel, nibh. Pellentesque wisi. Nullam malesuada. Morbi ut tellus ut pede tincidunt porta. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam congue neque id dolor.

Donec et nisl at wisi luctus bibendum. Nam interdum tellus ac libero. Sed sem justo, laoreet vitae, fringilla at, adipiscing ut, nibh. Maecenas non sem quis tortor eleifend fermentum. Etiam id tortor ac mauris porta vulputate. Integer porta neque vitae massa. Maecenas tempus libero a libero posuere dictum. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Aenean quis mauris sed elit commodo placerat. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Vivamus rhoncus tincidunt libero. Etiam elementum pretium justo. Vivamus est. Morbi a tellus eget pede tristique commodo. Nulla nisl. Vestibulum sed nisl eu sapien cursus rutrum.

Nulla non mauris vitae wisi posuere convallis. Sed eu nulla nec eros scelerisque

pharetra. Nullam varius. Etiam dignissim elementum metus. Vestibulum faucibus, metus sit amet mattis rhoncus, sapien dui laoreet odio, nec ultricies nibh augue a enim. Fusce in ligula. Quisque at magna et nulla commodo consequat. Proin accum-san imperdiet sem. Nunc porta. Donec feugiat mi at justo. Phasellus facilisis ipsum quis ante. In ac elit eget ipsum pharetra faucibus. Maecenas viverra nulla in massa.

Nulla ac nisl. Nullam urna nulla, ullamcorper in, interdum sit amet, gravida ut, risus. Aenean ac enim. In luctus. Phasellus eu quam vitae turpis viverra pellentesque. Duis feugiat felis ut enim. Phasellus pharetra, sem id porttitor sodales, magna nunc aliquet nibh, nec blandit nisl mauris at pede. Suspendisse risus risus, lobortis eget, semper at, imperdiet sit amet, quam. Quisque scelerisque dapibus nibh. Nam enim. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Nunc ut metus. Ut metus justo, auctor at, ultrices eu, sagittis ut, purus. Aliquam aliquam.

Capítulo 2

Estado de la Cuestión

2.1. Estado de la cuestión: Audio

2.1.1. Síntesis sonora

La síntesis de sonido es el proceso de generar señales de audio artificialmente mediante hardware electrónico o software, sin depender de la grabación de una fuente acústica real. Las herramientas diseñadas para este propósito se denominan sintetizadores, los cuales generan sonidos en base a unos parámetros modificables.

En el corazón de toda síntesis sonora se encuentra la onda sinusoidal, descrita por la ecuación fundamental:

$$x(t) = A \sin(2\pi ft + \phi) \quad (2.1)$$

donde A representa la **amplitud** (la altura del sonido, relacionada con el volumen), f es la **frecuencia** en hercios (que determina el tono, con mayores valores produciendo sonidos más agudos), t es el **tiempo**, y ϕ es la **fase inicial** en radianes (que define el punto de inicio de la oscilación). Esta onda senoidal pura es el elemento básico de toda síntesis, del cual se generan todos los sonidos.

El **teorema de Fourier** establece que cualquier forma de onda periódica, por compleja que sea, puede descomponerse en una suma de ondas sinusoidales de diferentes frecuencias, amplitudes y fases. Por esta razón, dominar la generación y manipulación de ondas sinusoidales es esencial para comprender cualquier técnica de síntesis sonora.

Históricamente, han existido diversas aproximaciones a la síntesis. Las más tradicionales incluyen la síntesis aditiva, que construye sonidos complejos sumando formas de onda sinusoidales de diferentes frecuencias y amplitudes; y la síntesis sustractiva, que esculpe el sonido partiendo de una forma de onda rica en frecuencias a la que se le aplican filtros para eliminar los componentes no deseados. Estas técnicas fundamentales abrieron el camino hacia métodos más eficientes pero matemáticamente más complejos, como la FM.

2.1.2. Síntesis por Modulación de Frecuencia (FM) y el Yamaha DX7

La **síntesis FM** es una tipo de síntesis descubierta a finales de los años sesenta (Chowning, 1973). Su funcionamiento se basa en utilizar un oscilador (denominado **modulador**) para alterar la frecuencia de otro oscilador (denominado **portador**). El oído humano interpreta esta interacción como la creación de timbres completamente nuevos y armónicamente ricos.

Esta tecnología se popularizó a nivel mundial en 1983 con el lanzamiento del **Yamaha DX7**, el primer sintetizador digital de éxito comercial masivo. Fue muy relevante debido a su capacidad para generar sonidos metálicos, eléctricos y campanados, completamente novedosos para la época. Sin embargo, la síntesis FM introdujo un problema grave: su **programación es notoriamente contraintuitiva**. Un cambio mínimo en un solo parámetro puede destruir por completo la estructura del sonido. Esta extrema sensibilidad es, precisamente, el principal desafío que justifica la aplicación de redes neuronales para automatizar la inferencia de sus parámetros.

Una formulación simple de la síntesis FM es:

$$x(t) = A_c \cos(2\pi f_c t + I \sin(2\pi f_m t)) \quad (2.2)$$

Aquí A_c es la **amplitud del portador**, f_c es su **frecuencia portadora** y f_m es la **frecuencia moduladora**. El parámetro I es el **índice de modulación**, que controla cuánto se desplaza la fase del portador y, por tanto, la riqueza armónica del sonido resultante.

2.1.3. Representación digital del sonido: La onda como vector

El sonido en el mundo físico es una onda continua producida por variaciones de presión en el aire. Sin embargo, para que una máquina pueda trabajar con audio, necesita "fotografiar" esa onda miles de veces por segundo en un proceso conocido como **muestreo** (sampling). Como resultado, la onda acústica se transforma en un vector numérico unidimensional. Cada uno de estos valores representa la amplitud de la señal en cada instante de tiempo. El número de muestras capturadas por segundo determina la calidad del audio, esto se denomina **frecuencia de muestreo** (sample rate).




Figura 2.1: Representación del muestreo de una onda continua a intervalos regulares. Fuente: Adaptado de Refraction Productions (2023).

Esta representación es uno de los estándares en tareas de **procesamiento de señales digitales (DSP)**. Sin embargo, existen otras representaciones, como el espectrograma.

2.1.4. Representación espectral: STFT y Espectrogramas

El **espectrograma** es la representación visual del sonido más utilizada en el aprendizaje profundo, ya que permite tratar el audio como una imagen donde el eje X es el tiempo, el Y la frecuencia y el color la intensidad. En la síntesis FM, esta representación es fundamental para que los modelos identifiquen texturas tímbricas complejas (?).




Figura 2.2: Ejemplo de un espectrograma. Fuente: Adaptado de ?.

En la parte superior de la **Figura 2.2** puede verse la forma de onda del sonido, que es la representación unidimensional del vector de audio. En la parte inferior se muestra el espectrograma, que es la representación 2D del mismo sonido.

Esta imagen se genera aplicando la **Transformada de Fourier de Tiempo Reducido (STFT)** sobre el vector de audio. El proceso consiste en dividir la señal

en fragmentos cortos mediante una ventana temporal y extraer el contenido frecuencial de cada uno (?). De este modo, se transforma una señal unidimensional en una estructura 2D que conserva la evolución temporal de las frecuencias, facilitando el análisis mediante redes neuronales convolucionales.

2.1.5. Escala de Mel

El eje de frecuencias (Y) en los espectrogramas suele tratarse como una escala lineal, donde los saltos entre frecuencias son uniformes. Sin embargo, esto puede generar una representación no intuitiva para la percepción humana, pues nosotros percibimos el sonido de forma no lineal, para ello se utiliza la **escala Mel**, la cual establece un umbral en una frecuencia específica (700 Hz), a partir de la cual la escala pasa de ser lineal a logarítmica.

Es un sistema de unidades diseñado para que distancias iguales en la escala correspondan a variaciones perceptuales uniformes en el tono (Stevens, Volkman, & Newman, 1937). Su relevancia radica en que el sistema auditivo posee una **mayor capacidad de percepción en las frecuencias bajas**.

La fórmula de conversión (2.3) es esencial para procesar sonidos de sintetizadores FM, los cuales generan una gran densidad de armónicos superiores que, en una escala lineal, ocuparían la mayor parte del espectro sin aportar información crítica para el oído humano.

$$m = 2595 \cdot \log_{10}(1 + f/700) \quad (2.3)$$

2.1.6. *Mel Frequency Cepstral Coefficients* (MFCC)

Los MFCC son un conjunto de coeficientes que representan la "huella" tímbrica de un sonido, es decir, aíslan el instrumento de la nota que este interpreta. Se obtienen aplicando la **Transformada de Coseno Discreta (DCT)** al espectrograma Mel para simplificar y organizar la información de las frecuencias (Davis & Mermelstein, 1980).

Si bien fueron el estándar en reconocimiento de voz, la tecnología actual prefiere el uso del espectrograma Mel completo. Este cambio se debe a que las redes neuronales convolucionales (CNN) logran mayor precisión al analizar la imagen sonora total, aprovechando detalles y matices que la compresión de la DCT suele eliminar en el proceso. Sin embargo, **como métrica de evaluación**, los MFCC siguen siendo útiles para comparar la similitud tímbrica entre el sonido original y el resintetizado.

2.2. Estado de la cuestión: IA aplicada al audio

2.2.1. CNNs en el dominio del audio

Las Redes Neuronales Convolucionales (CNNs) son un tipo de arquitectura de aprendizaje profundo diseñada para explotar la estructura espacial-local de los datos, es precisamente por esto que se usan tanto en tareas de imagen. Fueron propuestas

originalmente por LeCun et al. (1998) para el reconocimiento de caracteres escritos a mano. Su principio fundamental es el uso de filtros convolucionales de pequeño tamaño (kernels) que se deslizan sobre la entrada, compartiendo pesos a lo largo de todas las posiciones. Esto las hace invariantes a la traslación y dramáticamente más eficientes en parámetros que una red densa equivalente. La arquitectura típica alterna capas convolucionales, que extraen características locales, con capas de pooling, que reducen la dimensionalidad y aumentan el campo receptivo, construyendo así una jerarquía de características que va desde elementos simples, como bordes o gradientes, hacia representaciones abstractas de formas y texturas (Krizhevsky, Sutskever, & Hinton, 2012).

En el dominio del audio, las CNNs son eficaces porque pueden aprender patrones locales en el espectrograma, como la estructura armónica y el ruido de ataque. Se ha demostrado que modelos pre-entrenados en bases de datos masivas pueden transferir capacidades de detección de características generales a tareas específicas de síntesis (Kong et al., 2020). Al aplicar filtros convolucionales sobre las dimensiones de tiempo y frecuencia, la red identifica texturas tímbricas con una eficiencia muy superior a las redes densas tradicionales, capturando la identidad sonora de la modulación FM.

2.2.2. Audio Spectrogram Transformer (AST)

El estado del arte en el procesamiento de audio ha evolucionado de las arquitecturas convolucionales (CNN) hacia los Transformers, tras su éxito en el procesamiento de lenguaje natural (Vaswani et al., 2017). En el contexto del audio, el modelo de referencia es el Audio Spectrogram Transformer (AST) (Gong et al., 2021), que adapta la arquitectura de atención para trabajar directamente con espectrogramas. A diferencia de las CNN, que analizan patrones locales mediante filtros, el AST utiliza un mecanismo de auto-atención (self-attention). Este permite al modelo capturar relaciones globales y dependencias de largo alcance en el tiempo y la frecuencia, dividiendo el espectrograma en parches de datos (Gong et al., 2021).

Sin embargo, los Transformers presentan una complejidad computacional cuadrática y requieren volúmenes masivos de datos para superar a las CNN (Gong et al., 2021). Por ello, en tareas de sound matching con recursos limitados, como es nuestro caso, las arquitecturas convolucionales siguen siendo una opción preferente por su eficiencia.

2.2.3. Inferencia de parámetros en síntesis

El diseño automático de sonido busca encontrar los parámetros de un sintetizador que repliquen un audio objetivo. Los primeros enfoques exitosos con redes neuronales profundas utilizaron arquitecturas LSTM y CNN para mapear sonidos a las configuraciones de operadores de un Yamaha DX7 (Yee-King et al., 2018). Sin embargo, un hallazgo crítico transformó esta metodología: optimizar el modelo basándose exclusivamente en la distancia numérica entre parámetros es ineficiente.

Este fenómeno se debe a la falta de inyectividad del motor de síntesis, donde combinaciones de parámetros drásticamente diferentes pueden generar resultados

acústicos idénticos. Para solventar esta ambigüedad, se propuso el uso de funciones de pérdida basadas en la distancia entre los espectrogramas del audio original y el resintetizado (pérdida espectral) (Barkan et al., 2019). Esta evolución ha convergido en el uso de decodificadores avanzados, sintetizadores diferenciables como DDSF (Engel et al) y arquitecturas basadas en Transformers, que permiten una convergencia mucho más precisa pues priorizan la coherencia perceptiva del sonido sobre la coincidencia de valores numéricos.

2.2.4. Audio End-to-End vs. Parámetros + Espectrograma

El debate sobre la representación óptima divide a la comunidad entre el uso de características extraídas (como el espectrograma) y el procesamiento de la onda cruda (raw approach). Los modelos End-to-End permiten capturar micro-detalles temporales y de fase que se pierden en el espectrograma de magnitud (Oord et al., 2016). Recientemente, se ha propuesto un camino intermedio mediante el Procesamiento de Señales Digitales Diferenciable (DDSP), que integra el conocimiento de la síntesis clásica dentro de las redes neuronales, permitiendo que el modelo controle osciladores y filtros directamente mientras mantiene la interpretabilidad de los parámetros (Engel et al., 2020).

2.2.5. Datasets de referencia: NSynth y otros

Para entrenar modelos de inferencia, se requieren bases de datos extensas y etiquetadas. Además, en el contexto del audio, la calidad de la muestra es muy importante, pues en representaciones espectrograma el ruido puede hacer que la CNN detecte patrones equivocados.

El dataset NSynth es el estándar actual, proporcionando más de 300.000 notas individuales de diversos instrumentos con etiquetas detalladas de sus cualidades acústicas (Engel et al., 2017). Sin embargo, para proyectos centrados en síntesis FM, es habitual complementar estos datos mediante la generación sintética masiva utilizando emuladores como Dexed, que simula el Yamaha dx7, lo que garantiza una correspondencia exacta entre el audio y los parámetros internos del sintetizador. (Yee King) (Masuda)

2.3. Evaluación (mover?)

2.3.1. Fréchet Audio Distance (FAD)

La métrica *Fréchet Audio Distance* (FAD) Kevin Kilgour (2019) fue introducida originalmente por investigadores de Google AI y es utilizada actualmente en proyectos muy grandes como MusicLM Andrea Agostinelli (2023), pudiendo considerarse como el **estado del arte** para medir la calidad objetiva de los audios generados mediante Inteligencia Artificial, adaptando al dominio del audio las métricas utilizadas en la generación de imágenes.

Conceptualmente, el FAD deriva de *Fréchet Inception Distance* (FID), una métrica referente en la evaluación de modelos generativos de imágenes. Al igual que su predecesora, esta métrica no realiza comparación muestra a muestra, sino que compara características de alto nivel extraídas por una red neuronal profunda.

Para la extracción de estas características, el FAD utiliza un modelo llamado *VGGish*, un clasificador de audio entrenado con una base de datos de gran envergadura de vídeos de YouTube. Este modelo transforma la señal de audio en *log-mel features* extraídas del espectrograma de magnitud

Finalmente, la métrica se obtiene calculando la *Distancia de Fréchet* entre la música de referencia y la generada. Un valor de FAD reducido indica una estadística similar entre el audio de referencia y el generado.

Evolución Arquitectónica

3.1. Exploración de Paradigmas: Clasificación vs. Regresión

3.1.1. Enfoque de Clasificación

La clasificación es el paso previo natural a la búsqueda de un modelo de inferencia de parámetros. De esta manera, se puede comprobar de forma práctica que la red neuronal procesa el audio adecuadamente y es capaz de conservar su información acústica fundamental.

El **Prototipo 1** es una prueba de concepto para la primera aproximación al aprendizaje automático aplicado al audio. En él se utiliza un dataset reducido, construido con la librería NumPy, de alrededor de 50 archivos *.wav* de un segundo de duración. Estos audios se generan sintéticamente con frecuencias aleatorias y formas de onda básicas (*sine*, *square*, *sawtooth*, *triangle* y *noise*).

En la fase de preprocesamiento y entrenamiento, desarrollada utilizando TensorFlow, se opta por no aportar a la red formas de audio crudo. En su lugar, se extraen las características calculando los Coeficientes Cepstrales en las Frecuencias de Mel (MFCC) de cada muestra. El modelo tiene el objetivo de clasificar y asociar la matriz de coeficientes con la etiqueta correspondiente a su tipo de onda. A pesar de esto, al plantear una arquitectura básica no convolucional, la red neuronal carece de los mecanismos para realizar una interpretación correcta de los patrones bidimensionales de los MFCC. Como consecuencia, el modelo arroja una precisión muy baja.

El **Prototipo 2** se basa en el Prototipo 1. Sigue atendiendo al objetivo de la clasificación, pero tiene características que difieren del anterior. Esta vez, los audios se convierten a espectrogramas *.png* mediante el uso de la librería de *librosa*. De esta forma se consigue un menor coste computacional y de almacenamiento. Al tratarse realmente de imágenes, se pueden utilizar modelos preentrenados de visión capaces de clasificarlas.

En el entrenamiento se hace uso de **ResNet34 preentrenada** vía *fastAI*. Para su adaptación, se utilizan **DataBlocks**, una herramienta de *fastAI* mediante la cual

se especifican que las entradas son las imágenes (espectrogramas) y las salidas son las categorías (tipo de onda). El etiquetado de la categoría de cada archivo se obtiene a partir su nombre y se divide destinando un 80 % de las imágenes para entrenar y un 20 % para validación.

Como resultado de utilizar una red convolucional y la arquitectura externa **ResNet34**, el modelo obtuvo una buena precisión, especialmente identificando ondas puras dentro del rango entrenado.

3.1.2. Enfoque de Regresión

La clasificación sirvió como prueba de concepto y como primer acercamiento a un modelo de procesamiento de audio, permitiendo que se explorasen tecnologías, bibliotecas y métodos que serían de gran utilidad durante la totalidad de las fases del desarrollo.

Sin embargo, para la implementación de un modelo que cumpliera con la descripción del trabajo, se decide dar un salto hacia la síntesis paramétrica continua. Para ello, fue necesario tomar una decisión de diseño fundamental: la elección del motor de síntesis. Tras la evaluación de distintas alternativas, se optó por centrar el proyecto en la síntesis por Modulación de Frecuencia (FM). Esta técnica presenta ventajas claras para el aprendizaje automático. A diferencia de la síntesis aditiva, que requiere decenas de osciladores simultáneos, la síntesis FM es muy eficiente, consiguiendo generar timbres complejos a partir de un número reducido de parámetros. De esta forma, se puede comenzar utilizando, por ejemplo, la frecuencia portadora, el ratio y el índice de modulación, y luego ampliar el número de variables para conseguir sonidos más complejos. Estas características acotan la dimensionalidad del problema predictivo en un rango viable para la red neuronal.

Si bien con la clasificación queda validada la extracción de características acústicas, una vez tomada esta última decisión, deja de ser útil. Para la inferencia de parámetros de la síntesis FM, resulta obligatoria la evolución hacia una arquitectura de regresión.

Para el **Prototipo 3** se genera un dataset mediano de aproximadamente 15000 muestras, construido mediante un barrido de parámetros en un sintetizador FM de **pyo**. Para la reducción de la carga computacional y la optimización del espacio, se sustituye **librosa** por la librería de *torchaudio*. Esta permite transformar los archivos de audio (*.wav*) en tensores de espectrogramas (*.pt*), asociados mediante el uso de un (*.csv*) a sus valores numéricos. El 80 % del conjunto de datos se destina a entrenamiento y el otro 20 % a validación.

El entrenamiento se implementa mediante **PyTorch**. Se diseña una arquitectura convolucional propia (SmallCNNRegressor). La red neuronal se compone de dos bloques principales: uno de extracción de características y una cabeza de regresión.

El primer bloque recibe los espectrogramas en forma de tensores de un único canal (lo que equivaldría a imágenes en escala de grises) y los procesa en otros tres bloques convolucionales. Cada uno de estos aplica kernels de tamaño 3x3 (o núcleos convolucionales) que se deslizan sobre la matriz del espectrograma para extraer características espaciales, detectando así patrones visuales en la representación espectral del sonido. A esto le sigue una función de activación no lineal **ReLU** y una

capa de reducción espacial (**Max Pooling**). El último bloque convolucional termina en una capa de agrupamiento (**Adaptive Average Pooling**), que comprime los mapas de características a una matriz 4x4.

El siguiente paso es la cabeza de regresión, en donde la información espacio-temporal del espectrograma (extraída en el bloque anterior), se pasa a un vector de una única dimensión y atraviesa dos capas completamente conectadas (**Perceptrón Multicapa**). La primera, comprime la información a 128 neuronas, y la segunda, saca el vector por una dimensión de salida de tamaño 3, que se corresponde con los tres parámetros del sintetizador: frecuencia portadora, ratio y el índice de modulación.

El modelo optimiza el proceso de los espectrogramas mediante el algoritmo Adam, utilizando el Error Cuadrático Medio (MSELoss) como función de pérdida. Y, en cuanto al ciclo de entrenamiento, este se configuró con una duración de 5 épocas (*epochs*), un número bajo pero suficiente para analizar el comportamiento del modelo. En este prototipo se decidió no hacer una búsqueda extensa de hiperparámetros al tratarse de un prototipo intermedio, con un fin de experimentación inicial con la regresión.

A pesar de esto, se puede observar una precisión muy limitada en los resultados experimentales. Se consigue mantener un MSE bajo en el *Ratio* e *Index*, pero el error en el *Carrier* resulta desproporcionado, debido a operar en la escala de miles de hercios. De este prototipo se puede sacar la conclusión de que minimizar el error matemático sobre los parámetros no garantiza la similitud acústica del sonido generado y de la necesidad de trabajar sobre parámetros normalizados para contrarrestar las grandes diferencias en sus escalas.

3.2. El Problema de la Inyectividad y la Necesidad de una Arquitectura Compleja

El Prototipo 3 contiene una limitación fundamental muy relevante en la síntesis FM: su inyectividad es nula. Esto quiere decir que diferentes combinaciones de parámetros pueden dar lugar a sonidos idénticos. Un ejemplo, radical pero que explica muy bien este resultado, es un caso en el que el índice de modulación sea 0. En ese caso no es verdaderamente relevante el valor del ratio, sin embargo, la función de pérdida, implementada con **MSE**, penaliza gravemente que este difiera del original.

Otro ejemplo, más común, ocurre en los casos en los que se trabaja sobre un índice de modulación alto, de tal forma que la frecuencia moduladora predomina sobre la portadora. Si tenemos un *Carrier* de 1000 Hz y un *Ratio* de 1.0, la frecuencia moduladora resultante será de 1000 Hz, generándose los armónicos en saltos de mil en mil hercios. Por otro lado, con un *Carrier* de 2000 Hz y un *Ratio* de 0.5, se obtiene la misma moduladora de 1000 Hz y, por lo tanto, los mismos armónicos. Todo esto sumado a un índice de modulación alto, harían que estos dos audios, paramétricamente muy distantes, suenen muy similares al oído humano. Este obstáculo hace que se tenga que replantear la función de pérdida.

3.2.1. Prototipo 4: Red Convolutiva de Doble Cabeza

El **Prototipo 4** se diseña para solucionar el problema de la inyectividad, tratando de asegurar que la inferencia de parámetros se corresponda con la fidelidad acústica. Este modelo se basa en una arquitectura convolutiva de doble cabeza (**Encoder-Decoder**).

En cuanto al preprocesamiento del conjunto de datos, se implementa una mejora para evitar que la diferencia tan grande entre las escalas de diferentes parámetros (como la frecuencia portadora frente al ratio) comprometa el cálculo del gradiente. Los tensores se normalizan estadísticamente (**Z-score**), restando la media y dividiendo por la desviación estándar de cada parámetro.

Para cada parámetro x , el valor normalizado z se calcula según la Ecuación 3.1:

$$z = \frac{x - \mu}{\sigma} \quad (3.1)$$

Donde μ representa la media aritmética de dicho parámetro en todo el dataset de entrenamiento y σ su desviación estándar.

La topología de la red (CNNRegressor4), consta de un procesamiento dividido en varias fases:

Primero se pasa por un Codificador (**Encoder**), el cual consta de una secuencia de tres bloques convolutivos que convierten el espectrograma inicial en una representación comprimida, extrayendo así sus características fundamentales. Para ello, cada bloque aplica núcleos (kernels) de 3x3. Posteriormente, pasa por una capa de normalización por lotes (Batch Normalization), que estabiliza y acelera el entrenamiento, y una activación no lineal ReLU. Finalmente, se aplica una reducción espacial en cada bloque (Max Pooling). Con todo esto, la matriz se ha reducido a una octava parte de su tamaño original y la profundidad de la red ha incrementado de 1 a 128 canales. Como resultado, se obtiene una representación comprimida rica en características acústicas.

Al salir del **Encoder**, el flujo de datos atraviesa lo que se denomina como cuello de botella (**Bottleneck**). Este bloque convolutivo no aplica una reducción espacial, manteniendo estables las dimensiones de la matriz. Su función es duplicar el número de canales (profundidad del tensor), pasando de 128 a 256 canales. Esto se hace con la finalidad de mezclar los patrones que el **Encoder** ha extraído previamente, creando una representación densa y unificada.

Después se pasa por la fase de Inferencia Numérica, donde ocurre la regresión de los parámetros del sintetizador FM (frecuencia portadora, ratio e índice). Se aplica una capa de agrupamiento global (Adaptive Average Pooling) ya que los parámetros describen el sonido completo y no un punto temporal concreto en el espectrograma. Para ello, se calcula la media de todas las posiciones de cada canal, quedándose con un único número como resumen por canal. Finalmente, el vector unidimensional, resultado del proceso anterior, atraviesa un **Perceptrón Multicapa**, que lo proyecta hacia las tres neuronas de salida.

Por último, se encuentra la fase de Reconstrucción (**Decoder**), la cual se encarga de reconstruir el espectrograma original a partir de la representación comprimida del **Bottleneck**. Como el **Encoder** comprime tres veces, el **Decoder** descomprime tres veces. Para ello, utiliza tres capas convolutivas transpuestas (ConvTranspose2d).

El motivo para utilizar el **Decoder** es como método de regularización forzada del **Encoder**. En el caso en el que el codificador borre información importante, como armónicos o patrones temporales, que no afecte directamente a los parámetros de la regresión, el (**Decoder**) no será capaz de redibujar correctamente el espectrograma, disparando así el error en la función de pérdida híbrida. Aparte, si el **Bottleneck** no guarda suficiente información, ocurrirá lo mismo. Todo esto fuerza, mediante el cálculo de gradientes, a que las capas iniciales aprendan a conservar el timbre y la representación del sonido.

3.2.2. Prototipo 4: Función de Pérdida Híbrida

Con el objetivo de solucionar el problema de la inyectividad, se consolida el uso de utilizando Función de Pérdida Híbrida, abandonando el Error Cuadrático Medio (MSE). Esta función evalúa la pérdida de dos formas simultáneamente, dándole prioridad a la similitud y convergencia de espectrogramas (pérdida y convergencia espectral) y dejando en segundo plano la similitud de los parámetros (pérdida paramétrica).

Por un lado tenemos la **Pérdida y Convergencia Espectral**. Estas funciones son las principales para la composición del error, teniendo mucho más peso que la pérdida paramétrica, y estando encargadas de asegurar que un sonido generado sea acústicamente similar al original.

La **pérdida espectral** se calcula mediante el Error Cuadrático Medio (**L1 Loss**), el cual mide la diferencia directa entre espectrogramas (píxel a píxel) en escala logarítmica (dB), siendo la métrica de mayor peso para el error. Con esto se garantiza unos picos de energía y formas generales que coincidan en tiempo y frecuencia.

Matemáticamente, si S es el espectrograma original en decibelios y $\hat{S}$ el reconstruido, ambos con N elementos, la pérdida L1 se define como:

$$L_1 = \frac{1}{N} \sum_{i=1}^N |S_i - \hat{S}_i| \quad (3.2)$$

En cuanto a la **convergencia espectral**, es un refuerzo (tiene un peso bajo) para la pérdida espectral, que compara las magnitudes de forma relativa con la norma de Frobenius, capturando la estructura global del espectro (como los armónicos y la energía). Estas características son muy relevantes para encontrar una representación fiel al timbre original.

La convergencia espectral (C_S) emplea la norma de Frobenius ($\|\cdot\|_F$) sobre las magnitudes matriciales para medir la distancia relativa entre las energías, tal y como detalla la Ecuación 3.3:

$$C_S = \frac{\|S - \hat{S}\|_F}{\|S\|_F} \quad (3.3)$$

Por último se encuentra la **Pérdida Paramétrica**, aplicada mediante **SmoothL1**. Esta penaliza las diferencias en los parámetros del sintetizador, por lo que no se elimina totalmente la regresión numérica de los parámetros, pero se le da un peso considerablemente bajo.

La Ecuación 3.4 muestra el comportamiento por tramos de SmoothL1 para una predicción $\hat{y}$ frente a su valor real y :

$$L_{smooth} = \begin{cases} 0.5(y - \hat{y})^2, & \text{si } |y - \hat{y}| < 1 \\ |y - \hat{y}| - 0.5, & \text{en caso contrario} \end{cases} \quad (3.4)$$

La ponderación de los pesos en la función de pérdida híbrida es fundamental para el correcto aprendizaje del Modelo y también para solucionar el problema de la inyectividad. Se le otorga un peso completo (1.0) a la pérdida espectral, un peso medio (0.5) a la convergencia espectral y un peso muy bajo (0.05) a la pérdida paramétrica. De esta manera, en el caso de que la red infiera una serie de parámetros que difieran considerablemente de los parámetros originales, si sus espectrogramas son muy similares (y, por tanto, su timbre también lo es), el error será mínimo. El modelo debe memorizar números exactos, si no que analiza la imagen del sonido, su espectrograma.

Experimentación Previa

4.1. Limitaciones de Fréchet Audio Distance (FAD)

Para la primera evaluación del modelo, se seleccionó la métrica *Fréchet Audio Distance* (FAD), descrita en la Sección ???. Su implementación en el proyecto, se realiza a través de la comparación de dos conjuntos de datos: una muestra de 2.000 audios FM generados aleatoriamente y sus predicciones con el modelo utilizado en el *Prototipo 4*. El resultado obtenido fue de 0.9999, indica una similitud estadística casi absoluta entre las distribuciones de audio.

A pesar de que el resultado obtenido plantea una evaluación teóricamente óptima, el análisis profundo de los resultados y del funcionamiento de FAD indican una discrepancia. El motivo de la poca validez de la métrica en el proyecto, se atribuye a un error en la interpretación de su utilidad real, ya que el FAD está diseñado para evaluar la calidad global de modelos generativos ?, mientras que este proyecto se centra en la estimación de los parámetros que luego utiliza para generar audio FM. Puesto que tanto el conjunto de referencia como las predicciones se crean mediante síntesis FM, su huella espectral y sus características de alto nivel (*embeddings*) son casi idénticas ?. Por tanto, el FAD evalúa positivamente que el modelo ha aprendido a recrear el timbre o "textura" de la síntesis FM, pero, como se comentaba previamente, resulta una muestra ciega a precisión muestra a muestra. En resumen, se prioriza la verosimilitud estadística del sonido sobre la similitud de las muestras una a una ??.

4.2. Validación por Fuerza Bruta (Grid Search)

Una de las cuestiones principales que se plantean en el desarrollo de este proyecto es si el uso de un modelo de Inteligencia Artificial representa la aproximación más óptima para el objetivo de la inferencia de parámetros. Esta disyuntiva surge, sobre todo, al analizar los primeros prototipos, como el *Prototipo 4*, en el que se emplean únicamente 3 parámetros para la síntesis FM: *Carrier*, *Index* y *Ratio*. Debido al reducido tamaño de este espacio de parámetros, resulta lógico plantear en la viabilidad de realizar un método de búsqueda exhaustiva (*Grid Search*). Este enfoque consiste

en realizar un recorrido iterativo por todas las combinaciones posibles, evaluándolas y registrando aquellas configuraciones que presenten una mayor similitud acústica con respecto al sonido objetivo.

Por otro lado, surge la necesidad de encontrar un método robusto para evaluar la fidelidad del modelo de inferencia de parámetros, buscando una métrica que simule la percepción de un oído humano experto haría un oído humano experto. Esta necesidad y la cuestión anterior convergen en la fase de experimentación. De este modo, se consiguen probar diferentes métricas que evalúen la similitud acústica dentro del algoritmo de *Grid Search*, comprobando simultáneamente la viabilidad técnica del enfoque de fuerza bruta frente al modelo predictivo.

Para lograr esta simulación del sistema auditivo humano, la **Escala Mel** se ha consolidado como el estándar en el procesamiento digital de señales de audio. Esta métrica aplica una transformación logarítmica que modela el comportamiento no lineal del oído humano, el cual pierde resolución y sensibilidad con el aumento de la frecuencia.

Por otra parte, para este mismo fin también se contempla el uso de los *Mel Frequency Cepstral Coefficients* (MFCC). Esta métrica aplica una Transformada del Coseno Discreta (DCT) sobre un espectrograma previamente mapeado en la escala Mel. La principal diferencia, donde radica su interés, es la capacidad de aislar la envolvente espectral del sonido, consiguiendo una representación matemática precisa del timbre o la textura acústica del audio. Al comprimir la información en un vector de coeficientes de baja dimensionalidad, MFCC permite calcular eficientemente la distancia matemática entre el sonido objetivo y los sonidos conseguidos en las iteraciones del *Grid Search*.

4.2.1. Diseño experimental y parametrización del Grid Search

El espacio de parámetros del sintetizador FM seleccionado para el algoritmo de *Grid Search*, buscando un balance entre resolución de la búsqueda y coste computacional, fue el siguiente:

- **Carrier (Frecuencia portadora):** Rango de 100 Hz a 2000 Hz, con incrementos de 100 Hz (20 valores).
- **Ratio (Frecuencia moduladora):** Rango de 0.05 a 2.0, con incrementos de 0.05 (40 valores).
- **Index (Índice de modulación):** Rango de 1.0 a 10.0, con incrementos de 0.5 (19 valores).

Esta configuración genera una rejilla de **15.200 combinaciones únicas**. Por cada iteración del triple bucle, el algoritmo invoca genera un audio de un segundo de duración mediante síntesis FM. A continuación, se extraen las características acústicas de dicha muestra y se calcula el Error Cuadrático Medio (MSE) respecto a las características precalculadas del audio original.

4.2.2. Espectrograma de Mel

La mayor parte de los resultados ejecutados con la métrica Mel en *Grid Search*, muestran valores que difieren significativamente de los originales. Debido a la discretización del espacio de búsqueda, el algoritmo tiende a alcanzar mínimos locales manipulando parámetros secundarios para aproximar la distribución de energía evaluada por el Espectrograma Mel.

Un ejemplo claro de este comportamiento se observa al analizar una inferencia donde los parámetros objetivo eran $Carrier = 1055.54$ Hz, $Ratio = 0.704$ e $Index = 9.38$. Los resultados de los tres mejores candidatos del *Grid Search* fueron los siguientes:

```
=====
Tiempo total de ejecución: 1 minutos y 5.16 segundos
=====
```

```
#1 -> Error Mel: 113.6648 | Carrier: 400.0, Ratio: 1.85, Index: 9.5
#2 -> Error Mel: 126.5552 | Carrier: 400.0, Ratio: 1.85, Index: 9.0
#3 -> Error Mel: 148.8820 | Carrier: 400.0, Ratio: 1.85, Index: 10.0
```

Aunque la divergencia en la frecuencia portadora ($Carrier$) es superior a 600 Hz, el cálculo de la frecuencia moduladora latente ($f_m = Carrier \times Ratio$) explica esta selección. En el audio objetivo, la frecuencia moduladora es de $1055.54 \times 0.704 \approx 743.07$ Hz. Por otra parte, la frecuencia moduladora en la combinación seleccionada por el algoritmo es de $400.0 \times 1.85 = 740.0$ Hz.

Al operar con un índice de modulación elevado ($Index > 9$), la energía espectral de la frecuencia portadora se atenúa severamente, trasladando el peso acústico a las bandas laterales generadas por la modulación. El algoritmo de fuerza bruta, incapaz de seleccionar el tono original por la limitación de la rejilla, optó por anclar el parámetro $Carrier$ en 400 Hz para forzar un $Ratio$ que replicara con precisión la frecuencia moduladora original (740 Hz). Esto valida empíricamente que, sin un espacio de inferencia continuo como el que proporciona el modelo predictivo de IA, las métricas espectrales son susceptibles a la falsificación de la frecuencia fundamental mediante intermodulación armónica.

El siguiente ejemplo muestra qué ocurre si esta vez se utiliza un $Carrier$ que el algoritmo no pueda seleccionar por la limitación de la rejilla (saltos de 100 Hz) y un índice de modulación bajo.

Parámetros originales:

```
Carrier = 1752.58
Ratio = 0.62
Index = 1.03
```

La aproximación del algoritmo fue la siguiente:

```
=====
Tiempo total de ejecución: 1 minutos y 4.39 segundos
```

```
=====
```

```
#1 -> Error Mel: 176.1064 | Carrier: 1600.0, Ratio: 0.70, Index: 2.0
#2 -> Error Mel: 177.4902 | Carrier: 1600.0, Ratio: 0.70, Index: 1.5
#3 -> Error Mel: 189.0954 | Carrier: 1700.0, Ratio: 0.65, Index: 1.0
```

En este escenario de prueba, el algoritmo dejó en tercera posición a la opción con los valores más parecidos a la original Mientras que la tercera opción, al oído resulta muy similar pero desafinada, la primera opción difiere excesivamente.

Matemáticamente, al incrementar artificialmente el *Index*, el algoritmo aumenta la anchura de banda del espectro, "difuminando" la energía a lo largo de múltiples bandas laterales. Este espectro ensanchado logra solaparse parcialmente con la frecuencia objetivo (1752 Hz), minimizando el MSE global en la matriz. Sin embargo, acústicamente, el resultado es catastrófico: el algoritmo ha sacrificado un tono puro y definido por un sonido rico en armónicos y percusivo, únicamente para evadir la penalización de un mínimo local inaccesible.

4.2.3. Espectrograma MFCC

En contraposición a lo observado con el Espectrograma Mel, la evaluación mediante los Coeficientes Cepstrales en las Frecuencias de Mel (MFCC) obtiene unos resultados lo más cercanos posibles a los valores iniciales de los parámetros, teniendo en cuenta que la anchura de la rejilla impide que sean más exactos.

Por esta razón, el audio obtenido queda, en la mayoría de ocasiones, notablemente desafinado con respecto al original. Sin embargo, se consigue plasmar la *textura* (o timbre) del sonido de una manera prácticamente idéntica a la original, debido a la precisión en la inferencia de los parámetros de *Ratio* e *Index*.

Los siguientes resultados son los obtenidos con los mismo audios que los utilizados de ejemplo en Mel.

Parámetros originales:

```
Carrier = 1055.54
Ratio = 0.704
Index = 9.38
```

Aproximación del algoritmo:

```
=====
```

```
Tiempo total de ejecución: 1 minutos y 10.58 segundos
```

```
=====
```

```
#1 -> Error MFCC: 124.7339 | Carrier: 1100.0, Ratio: 0.70, Index: 9.0
#2 -> Error MFCC: 146.7065 | Carrier: 1100.0, Ratio: 0.70, Index: 8.5
#3 -> Error MFCC: 171.0587 | Carrier: 1100.0, Ratio: 0.65, Index: 9.5
```

Parámetros originales:

```
Carrier = 1752.58
Ratio = 0.62
Index = 1.03
```

La aproximación del algoritmo fue la siguiente:

```
=====
Tiempo total de ejecución: 1 minutos y 9.93 segundos
=====
```

```
#1 -> Error MFCC: 121.4236 | Carrier: 1700.0, Ratio: 0.70, Index: 1.0
#2 -> Error MFCC: 143.8489 | Carrier: 1700.0, Ratio: 0.65, Index: 1.0
#3 -> Error MFCC: 155.1412 | Carrier: 1800.0, Ratio: 0.65, Index: 1.5
```

En estos resultados se puede apreciar lo teorizado previamente, el algoritmo encuentra los valores más cercanos a los originales dentro de los saltos de la rejilla. Aun así, cabe mencionar que MFCC no es tan sensible a los cambios de *Pitch* como lo es Mel, lo que implica que, aun teniendo unos saltos minúsculos en el *Carrier*, MFCC no conseguiría en todas las ocasiones la nota exacta.

4.2.4. Conclusiones

El análisis de los datos obtenidos en estas pruebas ha servido, por un lado, para responder a las cuestiones iniciales y, por otro, ha planteado nuevas ideas y preguntas.

En cuanto a la viabilidad del método *Grid Search* para la inferencia de parámetros de un sintetizador FM, se demuestra con contundencia que los tiempos de ejecución (que aparecen en los resultados anteriores) de dicho algoritmo son órdenes de magnitud superiores a los obtenidos en la síntesis realizada por el modelo predictivo. Teniendo el primero una media aproximada de 1 minuto y 5 segundos para Mel y 1 minuto y 10 segundos para MFCC, frente a los 2 o 3 segundos que tarda el modelo de inferencia. A esto se le añade el hecho de que se está utilizando un tamaño de rejilla bajo de únicamente 15200 iteraciones, si se ampliaran estos números los tiempos aumentarían también.

Aparte de los tiempos de ejecución, cabe destacar la precisión. Mientras que el método *Grid Search* realiza una búsqueda discreta de valores, que está sujeta al tamaño de rejilla, la red neuronal es capaz de operar en un espacio continuo.

La siguiente cuestión planteada era la búsqueda de un método de evaluación del modelo de inferencia. Con los análisis llevados a cabo se ha podido comparar entre la opción de utilizar *Espectrogramas de Mel* o *Espectrogramas MFCC*. Se ha observado que, al utilizar la métrica obtenida con *Mel*, se van a evaluar de manera positiva combinaciones de parámetros con diferente *Index* que mantengan una energía espectral similar, sin importar de forma estricta si esta proviene de la frecuencia portadora o de las bandas laterales moduladoras. Esto deriva en cambios significativos en el timbre de la predicción frente al audio original. Por otro lado, la métrica obtenida con *MFCC* presenta una gran sensibilidad frente a los cambios en el timbre, lo que resulta de gran utilidad para la evaluación del modelo.

Por último, se deja planteada la idea de utilizar una función de pérdida híbrida que utilice tanto *Mel* como *MFCC*. La razón para llevar dicha implementación a cabo es que se ha visto, durante el proceso de investigación para las anteriores pruebas, ambos son el *estado del arte* en lo que a modelos predictivos de audio se refiere y se ha considerado que con una implementación híbrida con ellos, se podría extraer la ventaja de encontrar el *Pitch* de *Mel* y la de encontrar el timbre de *MFCC*.

Arquitectura Final

Se adjunta la Figura 5.1 con el objetivo de facilitar la comprensión del modelo del Prototipo 5. El trabajo queda dividido en 5 fases: generación de audio, conversión a tensores, preparación del dataset, entrenamiento (con múltiples opciones de arquitectura) e inferencia paramétrica.

5.1. Expansión Paramétrica: Evolventes y Generación Aleatoria del Dataset

Las predicciones del **Prototipo 4** consiguen replicar detalladamente el timbre. Sin embargo, los sonidos generados en esta etapa están muy alejados de las aplicaciones reales del **Sound Matching**. Por esta razón, se propone un nuevo modelo en el que se explora ampliar la dimensionalidad de 3 a 8 parámetros. A las variables fundamentales (frecuencia portadora, ratio e índice), se le añaden las envolventes temporales: la envolvente de amplitud (*attack*, *decay* y *sustain*) y la envolvente del índice de modulación (*attack* y *decay*).

Son precisamente estas características del **Prototipo 5**, por las que es necesario una nueva forma de generación del dataset. La ampliación de 3 a 8 parámetros hace computacional inviable generar el dataset mediante un barrido de combinaciones posibles. Para dar solución a esta limitación, se genera el dataset por muestreo aleatorio.

5.1.1. Generación y Tratamiento del Dataset

El sistema genera un número (N) de muestras de audio con valores continuos aleatorios, en base a unos rangos de valores específicos para cada parámetro. Para cada uno de ellos se utiliza una distribución uniforme, a excepción de la frecuencia portadora (*Carrier*) que se realiza en escala logarítmica. De esta forma se simula la percepción humana del sonido.

En primer lugar, se sintetizan los N archivos *.wav* mediante la librería **NumPy** y la formulación matemática de la FM (Fase 1). Se define una frecuencia de muestreo (*sample rate*) de 44100 Hz y se incrementa el tiempo de duración de 1 a 2 segundos,




Figura 5.1: Flujo de trabajo del Prototipo 5: desde la síntesis matemática hasta la inferencia y evaluación del modelo.

con el fin de asegurar un margen temporal necesario para analizar y percibir las variaciones en el sonido provocadas por las envolventes. Estas envolventes se generan sobre un vector de tiempo unificado.

En la Fase 2, los audios generados *.wav* se convierten a tensores nativos de *PyTorch*. Se cargan mediante *torchaudio* y se les aplica un suavizado de amplitud en los extremos (*fade-in* y *fade-out*) con el objetivo de evitar chasquidos o ruidos indeseados. Tras una normalización de pico, se aplican las dos transformaciones principales: de audio a espectrograma y de amplitud lineal a logarítmica (dB). Para la representación acústica, el programa permite elegir entre dos métodos, con el fin de llevar a cabo diferentes pruebas de experimentación. Por un lado, se encuentran los espectrogramas en formato lineal, mediante **STFT** con 513 *bins*¹ de frecuencia. Y por el otro lado, se da lugar a elegir un formato logarítmico-perceptual (**Mel** con 128 bandas), el cual tiene un mayor potencial para la representación del sonido de manera similar a la percibida por el humano. Posteriormente, se extrae la magnitud de la señal, se convierte a decibelios (dB) y se guarda como tensores (formato *.pt*). Además, se genera un archivo (*spec_mode.txt*) que indica el tipo de espectrograma utilizado.

Para terminar con el tratamiento del dataset, se estructuran los tensores en una clase Dataset de PyTorch (*SpectrogramTensorDataset*). Se lee el registro de etiquetas (*labels.csv*), el cual contiene todos los valores de los parámetros de cada

¹El término *bin* hace referencia los intervalos de la Transformada de Fourier (FFT). El tamaño de ventana utilizado para la creación de los espectrogramas es de 1024 ($N_{fft} = 1024$), lo que genera $1024/2 + 1 = 513$ intervalos o *bins* de frecuencias

audio, y se calcula la media y desviación estándar global de cada uno de ellos. Con estas estadísticas se aplica una normalización de puntuación estándar (*Z-score*), nivelando así las diferencias entre las escalas de los parámetros, consiguiendo igualar las importancias de cada uno en el cálculo del gradiente. Finalmente, el dataset se divide, mediante una semilla fija, en: 70 % para entrenamiento, 15 % validación y se guarda otro 15 % como conjunto de pruebas (*Test set*).

5.1.2. Entrenamiento

La fase de entrenamiento se caracteriza por permitir la elección de diferentes arquitecturas y funciones de pérdida con el fin de experimentar. De esta forma, se pueden probar diferentes combinaciones para ver cual es más interesante en tiempo o precisión.

- **Arquitecturas:** Se dispone de dos topologías convolucionales diferentes:
 - **CNNRegressorSimple:** Está formada por un *Encoder* de tres bloques convolucionales, un *Bottleneck* y una cabeza de regresión pura (*Global Average Pooling*). Esta última está conectada a un Perceptrón Multicapa que acaba en 8 neuronas. A pesar de que la red ejecuta un entrenamiento rápido, al carecer de reconstrucción no se garantiza que el *Encoder* esté extrayendo de manera acertada la estructura del espectrograma, prediciendo únicamente números.
 - **CNNRegressor5:** Se trata de una expansión del modelo anterior, incorporando una segunda cabeza de predicción. Se añade un *Decoder* que consta de 3 capas convolucionales traspuestas, las cuales tratan de reconstruir el espectrograma a partir del espacio latente. Así pues, esta etapa fuerza al *Encoder* a capturar la riqueza temporal y tímbrica del sonido para evitar un error grande.
- **Funciones de Pérdida:** Para el modelo simple, se evalúa la diferencia paramétrica únicamente mediante **SmoothL1 Loss**. Esta se utiliza por su robustez y versatilidad en la regresión numérica: cuando la diferencia entre el valor real y el predicho es muy pequeña, se comporta como un Error Cuadrático (L2), lo que suaviza la convergencia de gradientes; y ante desviaciones grandes, se asemeja al Error Absoluto (L1), de forma que los casos aislados que se alejan del resto no desestabilicen la red. Esta función de pérdida tiene la desventaja de no tener en cuenta la no-inyectividad de la síntesis FM.

En cuanto al modelo CNNRegressor5, se permite la elección de una de las siguientes funciones de pérdida:

- **HybridLoss:** Es una función de pérdida híbrida, que combina el Error Absoluto Medio (L1) de la reconstrucción del espectrograma, un refuerzo estructural de Convergencia Espectral (SC), y la penalización paramétrica anterior. La primera se lleva el peso principal (de 1.0), calcula el Error Absoluto Medio píxel a píxel entre el espectrograma original y el reconstruido (en decibelios). La Convergencia Espectral (SC) se aplica con un

peso medio (de 0.5) para evitar los espectros borrosos generados por L1. Esta métrica calcula la norma de Frobenius para evaluar la energía global (relación armónica), regularizando el timbre. A la penalización paramétrica se le da una importancia muy baja (0.05), ya que no es demasiado importante debido al carácter no inyectivo de la síntesis FM.

- **MultiScaleSpectralLoss:** Esta función está inspirada en el modelo de síntesis diferencial DDSP. Al estar utilizando espectrogramas, se simulan los distintos tamaños de ventana de Fourier mediante agrupamientos espaciales temporales (*Average Pooling*). Se agrupa en seis factores (de 1, 2, 4, 8, 16 y 32) y se mide el error en cada una de esas escalas, siendo la media aritmética de esos errores el valor de pérdida total. El cálculo del error de cada escala primero se calcula la diferencia sobre las magnitudes lineales, la cual es útil para capturar picos de energía que pueden ser breves. A esto se le suma después la diferencia sobre las magnitudes en decibelios (logarítmico), multiplicada por un factor α de 1.0, por lo que se le está dando la misma relevancia que el error lineal, capturando así perfectamente la envolvente global y los momentos de baja energía. Mediante esta función, se consigue comparar el sonido obtenido del original en varios niveles de resolución simultáneamente. Por último, se le suma el error paramétrico (*SmoothL1*) con un peso muy bajo (0.05) con el objetivo de que la red no deje de tener mínimamente en cuenta los valores de los parámetros.

En la etapa final del entrenamiento, se encuentra el algoritmo de retropropagación (*Backpropagation*), mediante el cual se actualizan los pesos para así minimizar el error en la red, calculando los gradientes del error con respecto a cada nodo. Para la actualización de los pesos se emplea el optimizador **Adam** (*Adaptive Moment Estimation*). Este se elige frente al descenso de gradiente común (SGD) debido al cálculo que hace de las tasas de aprendizaje adaptativas e independientes para cada parámetro. A parte, se guardan los pesos de la época que ha conseguido el mínimo histórico con respecto al error sobre el conjunto de validación. Estos valores se almacenan en un archivo de punto de control (*checkpoint.pth*) junto con el resto de información de contexto necesaria:

- **Parámetros de Desnormalización:** Contiene las medias y desviaciones estándar obtenidas en la Fase 3 sobre los parámetros. Estas son necesarias para poder revertir el Z-score en las futuras predicciones.
- **Contexto de Arquitectura:** Son las etiquetas que describen la topología (*arch*: simple o full) y el tipo de espectrogramas (*spec_mode*: stft o mel) que se han utilizado para el modelo.
- **Aislamiento de Datos:** Contiene los índices del conjunto de prueba (*test_indices*), necesario para la evaluación.

5.1.3. Inferencia

La fase 5 consiste en la inferencia de parámetros de síntesis FM, mediante el modelo entrenado previamente, a partir de audios.

Al inicio de esta fase, se instancia el modelo y carga el punto de control, que instancia automáticamente el tipo de red.

La inferencia comienza cuando se recibe un archivo de audio (*.wav*). En ese momento, se sigue el mismo flujo que en la Fase 2, transformando el audio en un tensor de espectrograma (del tipo indicado por *spec_mode*). Este se introduce en el modelo (*forward pass*), obteniendo así un vector latente de 8 valores, sobre el que se aplica una desnormalización (con los valores de Z-score almacenados en el *checkpoint*) que da como resultado la predicción de los parámetros.

En este punto, el sistema te permite llevar a cabo varias acciones diferentes mediante la interfaz gráfica (GUI). Por un lado, se puede realizar una comparación visual del espectrograma del audio predicho con el del audio original. Para ello, se sintetizan los parámetros obtenidos y los parámetros originales y se calculan sus espectrogramas. También se da la opción de comparar acústicamente el audio original con el sintetizado por los parámetros inferidos (mediante *sounddevice*) y de exportar estos a un sintetizador propio, con la opción de modificarlos manualmente.

5.1.4. Evaluación

La última fase se centra en la evaluación del rendimiento del sistema y en la experimentación en el uso de las diferentes combinaciones de arquitecturas y funciones de pérdida. Para ello, la fase se divide en dos vertientes: evaluación sobre *Test Set* y evaluación sobre *Benchmark*. En la primera, se utilizan las muestras reservadas en la división inicial del dataset (un 15%). Los índices exactos de dicha muestra, se consiguen del archivo de punto de control (*checkpoint*), evitando datos cruzados con los vistos en el entrenamiento. Y en cuanto a la evaluación sobre *Benchmark*, su objetivo es poner a prueba el manejo del modelo dada la característica inyectividad nula de la síntesis FM. Para ello, se diseña un banco de pruebas (*benchmark*) con 12 sonidos de referencia que abarcan todo el espacio tímbrico del sintetizador (desde un bajo limpio a sonidos agudos, complejos y muy ruidosos).

Sobre los resultados obtenidos por las dos vertientes previas, se pueden calcular diferentes métricas para la evaluación del modelo en ambos ámbitos:

- **Métricas Sobre Parámetros:** Estas evalúan el modelo en función de la precisión obtenida en los parámetros inferidos. Se emplean las métricas de: Error Cuadrático Medio (MSE), que penaliza las desviaciones paramétricas grandes entre predicción y original; Raíz del Error Cuadrático Medio (RMSE), que devuelve el error en las unidades originales de cada parámetro, consiguiendo ver de forma directa la precisión y así poder hacer comparaciones objetivas entre las distintas arquitecturas y funciones de pérdida; y Error Absoluto Medio (MAE), el cual es más robusto frente a valores atípicos. Estas métricas sufren ante el problema de la inyectividad nula en la síntesis FM, por lo que se utilizan principalmente como diagnóstico rápido.

- **Métricas de Audio:** Estas son mucho más interesantes para conseguir una evaluación similar a la que daría un oído experto, ya que vuelven a sintetizar los parámetros y realizan una comparativa perceptual de los sonidos. Primero se aplica la Distancia L1 en Espectrogramas Mel (*Mel l1*), la cual calcula el Error Absoluto Medio (L1) sobre las señales previamente transformadas a la escala Mel, consiguiendo así la sensibilidad logarítmica del oído humano. De igual manera se aplica la Distorsión Cepstral Mel (MCD - *Mel-Cepstral Distortion*). Es una métrica que trata de evaluar la similitud del timbre de los audios, extrayendo 13 Coeficientes Cepstrales en las Frecuencias de Mel (MFCC). El primer coeficiente, que representa la energía global, es descartado para que la métrica refleje exclusivamente el timbre (textura del sonido).
- **Métrica de Reconstrucción (Decoder L1):** En el caso en el que se utilice la arquitectura **CNNRegressor5**. Calcula el Error Absoluto Medio (L1) entre el espectrograma original y el reconstruido por la red, de forma que se consigue evaluar la asimilación de información en el espacio latente.

5.2. Interfaz Gráfica de la Aplicación

Para una mejor experiencia de uso y facilitar el entorno de entrenamientos y pruebas de la aplicación, se ha desarrollado una Interfaz Gráfica. Se trata de una serie de pantallas sencillas, programadas en Python mediante el uso de la librería *Tkinter*.

En la primera pantalla (5.2), se da la opción de elegir un modelo existente o de entrenarlo.

En caso de decidir cargar un modelo, se podrá seleccionar mediante el explorador de archivos. A continuación (5.3), existen dos posibilidades: probar predicciones independientes de audios o realizar una evaluación general. En la primera, se puede cargar un wav y generar una predicción, existiendo la posibilidad de compararlos auditivamente o gráficamente sus espectrogramas (en frecuencia lineal y en logarítmica) y de ejecutar un sintetizador. En la pantalla del sintetizador(5.4), aparecen los parámetros de la predicción y los del audio original (en caso de tenerlos), siendo modificables. Además, el teclado hace la función de teclas del sintetizador con el sonido generado por los parámetros seleccionados.

La sección del entrenamiento (5.5) es la dedicada a seleccionar varios aspectos relevantes, tanto para el tiempo y forma de entrenamiento como para la topología del modelo. Por un lado, se permite elegir si entrenar el modelo en CPU o en GPU, lo que afectará directamente a su tiempo de entrenamiento. Por el otro, hay que decidir que tipo de espectrograma, arquitectura del modelo y función de pérdida (explorados en el apartado anterior) van a ser los que definan el modelo. El siguiente campo de la pantalla incluye la opción de crear el dataset (explicado anteriormente) o cargar uno personalizado. En último lugar se encuentra el apartado de parámetros modificables para el entrenamiento, como son las épocas (*epoch*), la tasa de aprendizaje (*Learning Rate*) y los pesos de los parámetros de las funciones de pérdida.

5.3. Estructura del Código

Para asegurar la mantenibilidad y escalabilidad, el código se estructura mediante el principio de Separación de Responsabilidades (*Separation of Concerns*). Se divide así la aplicación en dos módulos diferentes:

- **Lógica (Backend):** Se encuentra en el archivo *logica.py*. Aquí se agrupan las funciones matemáticas para la síntesis, calculo de métricas, generación de espectrogramas, etc.
- **Vista y Controlador (Frontend):** Archivo *main.py*. Este implementa la interfaz, recibe los *inputs* del usuario y gestiona el flujo de llamadas a la lógica y los errores.

Adicionalmente, destaca el uso de la Programación Orientada a Objetos (POO) y el encapsulamiento. Estas características se aplican en la aplicación de la siguiente manera:

- **Clase App (*main.py*):** Se encarga de encapsular el estado global. Evita el uso de variables globales manteniendo las variables necesarias instanciadas en esta clase (*self.dataset_obj*, *self.pathModelo*, *self.model_trained*, etc).
- **Clase SpectrogramTensorDataset (*dataset.py*):** Hereda de la clase base de *Pytorch* de *torch.utils.data.Dataset*, teniendo acceso a métodos como el de procesamiento por lotes (*batching*). Asimismo, esta clase se encarga de los cálculos de estadísticas de normalización y mapeo de los archivos, de forma que desde fuera se obtienen los datos ya preparados mediante el método `__getitem__`.
- **Modelos y Funciones de Pérdida:** Como se ha mencionado previamente, existen diferentes arquitecturas y funciones de pérdida y todas ellas heredan de *nn.Modules*. En consecuencia, el código permite que la lógica del entrenamiento sea independiente del modelo exacto que se esté utilizando, lo que se conoce como **Polimorfismo**. Por otro lado, la clase *HybridLoss* encapsula la lógica de la convergencia espectral y la norma de Frobenius, manteniendo el entrenamiento ajeno a estas fórmulas.
- **FMSynth8Window:** La pantalla del sintetizador se encuentra totalmente desacoplada del resto de la lógica, siendo una clase independiente. De esta manera, se puede utilizar tanto desde la ejecución normal de la aplicación como de forma aislada, facilitando así su construcción, ampliación y pruebas aisladas.




Figura 5.2: Primera pantalla de la Interfaz Gráfica de la Aplicación, elección uso modelo o entrenamiento.




Figura 5.3: Pantalla en la que se pueden hacer pruebas con el modelo seleccionado.




Figura 5.4: Sintetizador FM de prueba.




Figura 5.5: Sintetizador FM de prueba.

Capítulo 6

Resultados y Evaluación

En este capítulo se muestran las pruebas realizadas sobre el prototipo 5 (5).

6.1. Definición de los Pipelines Experimentales

Como se explicó en el capítulo sobre la arquitectura final (5), el prototipo 5 consta de varias posibles arquitecturas y funciones de pérdida, que se pueden combinar dando lugar a seis diferentes configuraciones (o *Pipelines*). El diagrama 6.1 muestra las diferentes topologías que se dan. Las arquitecturas y funciones de pérdida están ordenadas de tal manera que arriba a la izquierda se encuentra la configuración más simple (de la que se esperan los peores resultados) y abajo a la derecha la más compleja (la más prometedora).

Con la evaluación y comparación de las diferentes configuraciones, se espera determinar cuál de ellas será la "definitiva", la que ofrezca mejores predicciones, pero teniendo también en cuenta sus tiempos de entrenamiento y la eficiencia general de las mismas.

6.2. Evaluación de las Diferentes Arquitecturas y Funciones de Pérdida

La evaluación de las diferentes topologías se ha llevado a cabo con un único dataset de 50000 audios (método de generación explicado aquí: 5.1.1), un número que ha resultado ser equilibrado, permitiendo unos resultados decentes sin suponer un incremento demasiado grande en los tiempos de entrenamiento de los modelos.

El número de épocas no se ha dejado fijo, se ha utilizado un valor de paciencia (*Early Stopping*) de 10 épocas. De esta manera, se comprueba el error de validación en cada época y si después de 10 seguidas no se ha mejorado su record histórico, la red deja de entrenarse. Así pues, se evita la Sobreadaptación (*Overfitting*) de la red neuronal, puesto que se evita un entrenamiento excesivo, y se ahorra tiempo de entrenamiento innecesario.

Por otro lado, se ha elegido un *Batch Size* de 32. Este, aparte de ser un estándar




Figura 6.1: Representación de las diferentes combinaciones de Arquitecturas y Funciones de Pérdida.

Pipeline	Métricas Paramétricas (RMSE) ↓			Métricas Acústicas ↓		
	Carrier (Hz)	Ratio	Index	Mel L1 (dB)	MCD	Decoder L1
P1	X.XX	X.XX	X.XX	X.XX	X.XX	N/A
P2	X.XX	X.XX	X.XX	X.XX	X.XX	N/A
P3	X.XX	X.XX	X.XX	X.XX	X.XX	X.XX
P4	X.XX	X.XX	X.XX	X.XX	X.XX	X.XX
P5	X.XX	X.XX	X.XX	X.XX	X.XX	X.XX
P6	X.XX	X.XX	X.XX	X.XX	X.XX	X.XX

Tabla 6.1: Comparativa de métricas paramétricas y acústicas sobre el Test Set para los 6 pipelines. Las flechas (↓) indican que un valor menor representa un mejor rendimiento. El Decoder L1 no aplica (N/A) en las arquitecturas simples.

dar, es un valor asumible por cualquier tarjeta gráfica moderna y que consigue una eficiencia adecuada.

Benchmark:

- **Tamaño del Dataset: 50000**
- **Valor de Paciencia: 10**
- ***Batch Size: 32***

6.2.1. P1: CNNRegressorSimple: SmoothL1, STFT lineal

6.2.2. P2: CNNRegressorSimple: SmoothL1, Mel (log-perceptual)

6.2.3. P3: CNNRegressor5: HybridLoss, STFT lineal

6.2.4. P4: CNNRegressor5: HybridLoss, Mel (log-perceptual)

6.2.5. P5: CNNRegressor5: MultiScaleSpectralLoss, STFT lineal

6.2.6. P6: CNNRegressor5: MultiScaleSpectralLoss, Mel (log-perceptual)

6.3. Comparación de los Resultados Obtenidos

Conclusiones y Trabajo Futuro

Conclusiones del trabajo y líneas de trabajo futuro.

Antes de la entrega de actas de cada convocatoria, en el plazo que se indica en el calendario de los trabajos de fin de grado, el estudiante entregará en el Campus Virtual la versión final de la memoria en PDF.

Introduction

Introduction to the subject area. This chapter contains the translation of Chapter 1.

Conclusions and Future Work

Conclusions and future lines of work. This chapter contains the translation of Chapter 7.

Contribuciones Personales

David Cendejas Rodríguez

Mis principales contribuciones a este trabajo se han centrado en el liderazgo del desarrollo técnico, la investigación de arquitecturas de Deep learning y la implementación de los diversos prototipos que han dado forma al sistema final, el prototipo 5. Mi labor ha abarcado desde el planteamiento arquitectónico inicial hasta el entrenamiento y validación de los modelos, asumiendo la responsabilidad de investigar las tecnologías de Machine Learning y Deep Learning aplicadas al ámbito del audio. Este proceso ha supuesto un reto constante, especialmente al abordar la síntesis FM, debido a problemas intrínsecos como la nula inyectividad y la extrema sensibilidad de sus parámetros, factores que han condicionado directamente la convergencia y el rendimiento de nuestro modelo de Sound Matching.

Debido a ello, también he sido el principal responsable del desarrollo del contenido del Estado de la Cuestión de la memoria, así como realizando los diagramas necesarios para las partes más técnicas.

Paralelamente, he llevado a cabo una exploración técnica profunda sobre las representaciones de los datos y las estrategias de normalización. Esta parte del trabajo ha sido fundamental para transformar señales de audio en estructuras de datos procesables, como tensores espectrograma, asegurando la estabilidad del entrenamiento. En este sentido, diseñé e implementé pipelines robustos para el preprocesamiento de audio, garantizando que la entrada al modelo fuera óptima para el aprendizaje de las características tímbricas y unificarlo a los procesos de inferencia y evaluación, permitiendo que el sistema se comportara y escalara de forma coherente en todas sus fases del desarrollo.

En lo relativo a la ingeniería de software, he sido el principal responsable de la implementación del código en Python, aplicando principios de Programación Orientada a Objetos para garantizar un sistema modular y escalable. Debido a la naturaleza investigadora y no lineal del proyecto, el código evolucionó de forma orgánica tras cada reunión con los tutores y la revisión de literatura técnica. Esto me exigió realizar constantes tareas de abstracción y refactorización para evitar la redundancia y mantener la encapsulación, asegurando siempre la eficiencia computacional y la legibilidad del software. Asimismo, gestioné íntegramente las fases de depuración y manejo de errores, lo que resultó crucial para asegurar la integridad de los resultados

obtenidos en un entorno de desarrollo tan dinámico.

Finalmente, al disponer del hardware con mayor capacidad de cómputo del equipo, asumí la responsabilidad técnica de la fase de entrenamiento: Configuración de entornos de ejecución y gestión de recursos. Monitorización de métricas de evaluación estándar en la industria del Machine Learning para validar el rendimiento de los modelos en inferencia. Ajuste de hiperparámetros basado en la observación directa de las curvas de aprendizaje. Y entrenamiento de los modelos usados por mi compañero para realizar las pruebas y comparaciones.

Ángel Jiménez Izquierdo

Al menos dos páginas con las contribuciones del estudiante 2. En caso de que haya más estudiantes, copia y pega una de estas secciones.

Bibliografía

*Y así, del mucho leer y del poco dormir, se
le secó el cerebro de manera que vino a
perder el juicio.*

(modificar en Cascaras\bibliografia.tex)

Miguel de Cervantes Saavedra

ANDREA AGOSTINELLI, Z. B. J. E. M. V. A. C. Q. H. A. J. A. R. M. T. M. S.
N. Z. C. F., TIMO I.DENK. Musiclm: Generating music from text. Disponible
en <https://arxiv.org/pdf/2301.11325>.

KEVIN KILGOUR, D. R. M. S., MAURICIO ZULUAGA. Fréchet audio distance: A reference-free metric for evaluating music enhancement algorithms. Disponible en https://www.isca-archive.org/interspeech_2019/kilgour19_interspeech.pdf.

REFRACTION PRODUCTIONS. ¿qué es frecuencia de muestreo, profundidad de resolución de bits en audio? 2023. Accedido: 13-05-2026.

Apéndice A

Título del Apéndice A

Los apéndices son secciones al final del documento en las que se agrega texto con el objetivo de ampliar los contenidos del documento principal.

Apéndice	B
----------	----------

Título del Apéndice B

Se pueden añadir los apéndices que se consideren oportunos.

Este texto se puede encontrar en el fichero Cascaras/fin.tex. Si deseas eliminarlo, basta con comentar la línea correspondiente al final del fichero TFGTeXiS.tex.

*–¿Qué te parece desto, Sancho? – Dijo Don Quijote –
Bien podrán los encantadores quitarme la ventura,
pero el esfuerzo y el ánimo, será imposible.*

*Segunda parte del Ingenioso Caballero
Don Quijote de la Mancha
Miguel de Cervantes*

*–Buena está – dijo Sancho –; fírmela vuestra merced.
–No es menester firmarla – dijo Don Quijote–,
sino solamente poner mi rúbrica.*

*Primera parte del Ingenioso Caballero
Don Quijote de la Mancha
Miguel de Cervantes*

Bibliografía

*Y así, del mucho leer y del poco dormir, se
le secó el cerebro de manera que vino a
perder el juicio.*

(modificar en Cascaras\bibliografia.tex)

Miguel de Cervantes Saavedra

ANDREA AGOSTINELLI, Z. B. J. E. M. V. A. C. Q. H. A. J. A. R. M. T. M. S.
N. Z. C. F., TIMO I.DENK. Musiclm: Generating music from text. Disponible en
<https://arxiv.org/pdf/2301.11325>.

KEVIN KILGOUR, D. R. M. S., MAURICIO ZULUAGA. Fréchet audio distance: A reference-
free metric for evaluating music enhancement algorithms. Disponible en https://www.isca-archive.org/interspeech_2019/kilgour19_interspeech.pdf.

REFRACTION PRODUCTIONS. ¿qué es frecuencia de muestreo, profundidad de resolución
de bits en audio? 2023. Accedido: 13-05-2026.