

Análisis Técnico y Evaluación del Modelo de Síntesis FM

David Cendejas Rodríguez y Ángel Jiménez Izquierdo
Borrador para reunión con experto

24 de abril de 2026

Resumen

Este documento detalla el proceso de evaluación del modelo de predicción de parámetros para síntesis FM. Se analiza la discrepancia entre métricas de clasificación global (FAD) y la percepción auditiva del tono (Pitch), proponiendo un sistema de validación basado en búsqueda en rejilla (Grid Search) utilizando coeficientes cepstrales (MFCC) para solventar los problemas de no-unicidad armónica.

Índice

1. Evaluación y Métricas del Modelo	2
1.1. Limitaciones de Fréchet Audio Distance (FAD)	2
1.2. Validación por Fuerza Bruta (Grid Search)	2
1.2.1. Diseño experimental y parametrización del Grid Search	3
1.2.2. Espectrograma de Mel	3
1.2.3. Espectrograma MFCC	5
1.2.4. Conclusiones	6
2. Evolución del Modelo: Prototipo 5	6
2.1. Ampliación del espacio de parámetros: La Envolvente	6

1. Evaluación y Métricas del Modelo

1.1. Limitaciones de Fréchet Audio Distance (FAD)

Para la evaluación del modelo, se seleccionó la métrica *Fréchet Audio Distance* (FAD) [1]. Esta herramienta, introducida originalmente por investigadores de Google AI, es utilizada actualmente en proyectos muy grandes como MusicLM [2], pudiendo considerarse como el **estado del arte** para medir la calidad objetiva de los audios generados mediante Inteligencia Artificial, adaptando al dominio del audio las métricas utilizadas en la generación de imágenes.

Conceptualmente, el FAD deriva de *Fréchet Inception Distance* (FID), una métrica referente en la evaluación de modelos generativos de imágenes. Al igual que su predecesora, esta métrica no realiza comparación muestra a muestra, sino que compara características de alto nivel extraídas por una red neuronal profunda.

Para la extracción de estas características, el FAD utiliza un modelo llamado *VGGish*, un clasificador de audio entrenado con una base de datos de gran envergadura de vídeos de YouTube. Este modelo transforma la señal de audio en *log-mel features* extraídas del espectrograma de magnitud

Finalmente, la métrica se obtiene calculando la *Distancia de Fréchet* entre la música de referencia y la generada. Un valor de FAD reducido indica una estadística similar entre el audio de referencia y el generado.

Para la implementación de la métrica FAD en el proyecto, se compararon dos conjuntos de datos: una muestra de 2.000 audios FM generados aleatoriamente y sus predicciones con el modelo utilizado en el *Prototipo 4*. El resultado obtenido fue de 0.9999, un valor que, según la literatura de referencia, indica una similitud estadística casi absoluta entre las distribuciones de audio.

A pesar de que el resultado obtenido planteaba una evaluación teóricamente óptima, el análisis cualitativo reveló una discrepancia. El motivo de la poca validez de la métrica en el proyecto, se atribuye a un sesgo de interpretación de su utilidad real, ya que el FAD está diseñado para evaluar la calidad global de modelos generativos [1], mientras que este proyecto se centra en la estimación de los parámetros que luego utiliza para generar audio FM. Puesto que tanto el conjunto de referencia como las predicciones se crean mediante síntesis FM, su huella espectral y sus características de alto nivel (*embeddings*) son casi idénticas [1]. Por tanto, el FAD evalúa positivamente que el modelo ha aprendido a recrear el timbre o "textura" de la síntesis FM, pero, como se comentaba previamente, resulta una muestra ciega a precisión muestra a muestra. En resumen, se prioriza la verosimilitud estadística del sonido sobre la identidad exacta del mismo [1, 2].

1.2. Validación por Fuerza Bruta (Grid Search)

Una de las cuestiones principales que se plantean en el desarrollo de este proyecto es si el uso de un modelo de Inteligencia Artificial representa la aproximación más óptima para el objetivo de la inferencia de parámetros. Esta disyuntiva surge, sobre todo, al analizar los primeros prototipos, como el *Prototipo 4*, en el que se emplean únicamente 3 parámetros para la síntesis FM: *Carrier*, *Index* y *Ratio*. Debido al reducido tamaño de este espacio de parámetros, resulta lógico plantear en la viabilidad de realizar un método de búsqueda exhaustiva (*Grid Search*). Este enfoque consiste en realizar un recorrido iterativo por todas las combinaciones posibles, evaluándolas y registrando aquellas configuraciones que presenten una mayor similitud acústica con respecto al sonido objetivo.

Por otro lado, surge la necesidad de encontrar un método robusto para evaluar la fidelidad del modelo de inferencia de parámetros, buscando una métrica que simule la percepción de un oído humano experto haría un oído humano experto. Esta necesidad y la cuestión anterior convergen en la fase de experimentación. De este modo, se consiguen probar diferentes métricas que evalúen la similitud acústica dentro del algoritmo de *Grid Search*, comprobando simultáneamente la viabilidad técnica del enfoque de fuerza bruta frente al modelo predictivo.

Para lograr esta simulación del sistema auditivo humano, la **Escala Mel** se ha consolidado como el estándar en el procesamiento digital de señales de audio. Esta métrica aplica una transformación logarítmica que modela el comportamiento no lineal del oído humano, el cual pierde resolución y sensibilidad con el aumento de la frecuencia.

Por otra parte, para este mismo fin también se contempla el uso de los *Mel Frequency Cepstral Coefficients* (MFCC). Esta métrica aplica una Transformada del Coseno Discreta (DCT) sobre un espectrograma previamente mapeado en la escala Mel. La principal diferencia, donde radica su interés, es la capacidad de aislar la envolvente espectral del sonido, consiguiendo una representación matemática precisa del timbre o la textura acústica del audio. Al comprimir la información en un vector de coeficientes de baja dimensionalidad, MFCC permite calcular eficientemente la distancia matemática entre el sonido objetivo y los sonidos conseguidos en las iteraciones del *Grid Search*.

1.2.1. Diseño experimental y parametrización del Grid Search

El espacio de parámetros del sintetizador FM seleccionado para el algoritmo de *Grid Search*, buscando un balance entre resolución de la búsqueda y coste computacional, fue el siguiente:

- **Carrier (Frecuencia portadora):** Rango de 100 Hz a 2000 Hz, con incrementos de 100 Hz (20 valores).
- **Ratio (Relación armónica):** Rango de 0.05 a 2.0, con incrementos de 0.05 (40 valores).
- **Index (Índice de modulación):** Rango de 1.0 a 10.0, con incrementos de 0.5 (19 valores).

Esta configuración genera una rejilla de **15.200 combinaciones únicas**. Por cada iteración del triple bucle, el algoritmo invoca el motor de síntesis FM para generar una muestra de audio de un segundo de duración. A continuación, se extraen las características acústicas de dicha muestra y se calcula el Error Cuadrático Medio (MSE) respecto a las características precalculadas del audio original.

1.2.2. Espectrograma de Mel

La mayor parte de los resultados ejecutados con la métrica Mel en *Grid Search*, muestran valores que difieren significativamente de los originales. Debido a la discretización del espacio de búsqueda, el algoritmo tiende a alcanzar mínimos locales manipulando parámetros secundarios para aproximar la distribución de energía evaluada por el Espectrograma Mel.

Un ejemplo claro de este comportamiento se observa al analizar una inferencia donde los parámetros objetivo eran $Carrier = 1055,54$ Hz, $Ratio = 0,704$ e $Index = 9,38$. Los resultados de los tres mejores candidatos del *Grid Search* fueron los siguientes:

=====

Tiempo total de ejecución: 1 minutos y 5.16 segundos

=====

#1 -> Error Mel: 113.6648 | Carrier: 400.0, Ratio: 1.85, Index: 9.5
#2 -> Error Mel: 126.5552 | Carrier: 400.0, Ratio: 1.85, Index: 9.0
#3 -> Error Mel: 148.8820 | Carrier: 400.0, Ratio: 1.85, Index: 10.0

Aunque la divergencia en la frecuencia portadora (f_{carrier}) es superior a 600 Hz, el cálculo de la frecuencia moduladora latente ($f_m = \text{Carrier} \times \text{Ratio}$) explica esta selección. En el audio objetivo, la frecuencia moduladora es de $1055,54 \times 0,704 \approx 743,07$ Hz. Por otra parte, la frecuencia moduladora en la combinación seleccionada por el algoritmo es de $400,0 \times 1,85 = 740,0$ Hz.

Al operar con un índice de modulación elevado ($\text{Index} > 9$), la energía espectral de la frecuencia portadora se atenúa severamente, trasladando el peso acústico a las bandas laterales generadas por la modulación. El algoritmo de fuerza bruta, incapaz de seleccionar el tono original por la limitación de la rejilla, optó por anclar el parámetro *Carrier* en 400 Hz para forzar un *Ratio* que replicara con precisión la frecuencia moduladora original (740 Hz). Esto valida empíricamente que, sin un espacio de inferencia continuo como el que proporciona el modelo predictivo de IA, las métricas espectrales son susceptibles a la falsificación de la frecuencia fundamental mediante intermodulación armónica.

El siguiente ejemplo muestra qué ocurre si esta vez se utiliza un *Carrier* que el algoritmo no pueda seleccionar por la limitación de la rejilla (saltos de 100 Hz) y un índice de modulación bajo.

Parámetros originales:

Carrier = 1752.58
Ratio = 0.62
Index = 1.03

La aproximación del algoritmo fue la siguiente:

=====

Tiempo total de ejecución: 1 minutos y 4.39 segundos

=====

#1 -> Error Mel: 176.1064 | Carrier: 1600.0, Ratio: 0.70, Index: 2.0
#2 -> Error Mel: 177.4902 | Carrier: 1600.0, Ratio: 0.70, Index: 1.5
#3 -> Error Mel: 189.0954 | Carrier: 1700.0, Ratio: 0.65, Index: 1.0

En este escenario de prueba, el algoritmo dejó en tercera posición a la opción con los valores más parecidos a la original. Mientras que la tercera opción, al oído resulta muy similar pero desafinada, la primera opción difiere excesivamente.

Matemáticamente, al incrementar artificialmente el *Index*, el algoritmo aumenta la anchura de banda del espectro, "difuminando" la energía a lo largo de múltiples bandas laterales. Este espectro ensanchado logra solaparse parcialmente con la frecuencia objetivo (1752 Hz), minimizando el MSE global en la matriz. Sin embargo, acústicamente, el resultado es catastrófico: el algoritmo ha sacrificado un tono puro y definido por un sonido rico en armónicos y percusivo, únicamente para evadir la penalización de un mínimo local inaccesible.

1.2.3. Espectrograma MFCC

En contraposición a lo observado con el Espectrograma Mel, la evaluación mediante los Coeficientes Cepstrales en las Frecuencias de Mel (MFCC) obtiene unos resultados lo más cercanos posibles a los valores iniciales de los parámetros, teniendo en cuenta que la anchura de la rejilla impide que sean más exactos.

Por esta razón, el audio obtenido queda, en la mayoría de ocasiones, notablemente desafinado con respecto al original. Sin embargo, se consigue plasmar la *textura* (o timbre) del sonido de una manera prácticamente idéntica a la original, debido a la precisión en la inferencia de los parámetros de *Ratio* e *Index*.

Los siguientes resultados son los obtenidos con los mismo audios que los utilizados de ejemplo en Mel.

Parámetros originales:

```
Carrier = 1055.54
Ratio = 0.704
Index = 9.38
```

Aproximación del algoritmo:

```
=====
Tiempo total de ejecución: 1 minutos y 10.58 segundos
=====

#1 -> Error MFCC: 124.7339 | Carrier: 1100.0, Ratio: 0.70, Index: 9.0
#2 -> Error MFCC: 146.7065 | Carrier: 1100.0, Ratio: 0.70, Index: 8.5
#3 -> Error MFCC: 171.0587 | Carrier: 1100.0, Ratio: 0.65, Index: 9.5
```

Parámetros originales:

```
Carrier = 1752.58
Ratio = 0.62
Index = 1.03
```

La aproximación del algoritmo fue la siguiente:

```
=====
Tiempo total de ejecución: 1 minutos y 9.93 segundos
=====

#1 -> Error MFCC: 121.4236 | Carrier: 1700.0, Ratio: 0.70, Index: 1.0
#2 -> Error MFCC: 143.8489 | Carrier: 1700.0, Ratio: 0.65, Index: 1.0
#3 -> Error MFCC: 155.1412 | Carrier: 1800.0, Ratio: 0.65, Index: 1.5
```

En estos resultados se puede apreciar lo teorizado previamente, el algoritmo encuentra los valores más cercanos a los originales dentro de los saltos de la rejilla. Aun así, cabe mencionar que MFCC no es tan sensible a los cambios de *Pitch* como lo es Mel, lo que implica que, aun teniendo unos saltos minúsculos en el *Carrier*, MFCC no conseguiría en todas las ocasiones la nota exacta.

1.2.4. Conclusiones

El análisis de los datos obtenidos en estas pruebas ha servido, por un lado, para responder a las cuestiones iniciales y, por otro, ha planteado nuevas ideas y preguntas.

En cuanto a la viabilidad del método *Grid Search* para la inferencia de parámetros de un sintetizador FM, se demuestra con contundencia que los tiempos de ejecución (que aparecen en los resultados anteriores) de dicho algoritmo son órdenes de magnitud superiores a los obtenidos en la síntesis realizada por el modelo predictivo. Teniendo el primero una media aproximada de 1 minuto y 5 segundos para Mel y 1 minuto y 10 segundos para MFCC, frente a los 2 o 3 segundos que tarda el modelo de inferencia. A esto se le añade el hecho de que se está utilizando un tamaño de rejilla bajo de únicamente 15200 iteraciones, si se ampliasen estos números los tiempos aumentarían también.

Aparte de los tiempos de ejecución, cabe destacar la precisión. Mientras que el método *Grid Search* realiza una búsqueda discreta de valores, que está sujeta al tamaño de rejilla, la red neuronal es capaz de operar en un espacio continuo.

La siguiente cuestión planteada era la búsqueda de un método de evaluación del modelo de inferencia. Con los análisis llevados a cabo se ha podido comparar entre la opción de utilizar *Espectrogramas de Mel* o *Espectrogramas MFCC*. Se ha observado que, al utilizar la métrica obtenida con *Mel*, se van a evaluar de manera positiva combinaciones de parámetros con diferente *Index* que mantengan una energía espectral similar, sin importar de forma estricta si esta proviene de la frecuencia portadora o de las bandas laterales moduladoras. Esto deriva en cambios significativos en el timbre de la predicción frente al audio original. Por otro lado, la métrica obtenida con *MFCC* presenta una gran sensibilidad frente a los cambios en el timbre, lo que resulta de gran utilidad para la evaluación del modelo.

Por último, se deja planteada la idea de utilizar una función de pérdida híbrida que utilice tanto *Mel* como *MFCC*. La razón para llevar dicha implementación a cabo es que se ha visto, durante el proceso de investigación para las anteriores pruebas, ambos son el *estado del arte* en lo que a modelos predictivos de audio se refiere y se ha considerado que con una implementación híbrida con ellos, se podría extraer la ventaja de encontrar el *Pitch* de *Mel* y la de encontrar el timbre de *MFCC*.

2. Evolución del Modelo: Prototipo 5

2.1. Ampliación del espacio de parámetros: La Envolvente

Referencias

- [1] Kilgour, K., Zuluaga, M., Roblek, D., & Sharifi, M. (2019). *Fréchet Audio Distance: A Reference-free Metric for Evaluating Music Enhancement Algorithms*. Interspeech 2019, Graz, Austria, pp. 2350-2354.
- [2] Agostinelli, A., Denk, T. I., Borsos, Z., Engel, J., Verzetti, M., & Roberts, A. (2023). *MusicLM: Generating Music From Text*. arXiv preprint arXiv:2301.11325.